



ilce - institut de lutte contre
la criminalité économique

heg - haute école de gestion

arc



Travail de master

Élaboration d'un modèle actionnable pour la détection proactive des petites annonces frauduleuses.

Travail de master réalisé entre juillet et
novembre 2024 en vue de l'obtention du
Master of Advanced Studies en Lutte contre la
criminalité économique (MAS LCE)

2023-2024

Etudiant : Graz David

Experts : Julien Pasquier, Thierry Chuat

Date : 15 novembre 2024

Clause de confidentialité :

OUI ☐ NON ☒

Remerciements

Je tiens à remercier toutes les personnes qui ont contribué à la réalisation de mon travail et qui m'ont aidée. Je souhaite tout d'abord remercier mes experts, Julien Pasquier et Thierry Chuat. Je les remercie de m'avoir orientée, aidée et conseillée.

Mes sincères remerciements aux membres des polices cantonales, pour leur participation de m'avoir donné l'occasion d'étudier un sujet de recherche passionnant. Un chaleureux merci à toute l'équipe de l'ILCE.

Je tiens à témoigner toute ma reconnaissance aux personnes suivantes, pour leur aide dans la réalisation de cette formation : Emmanuel, Fabienne, Isabelle, Olivier, Quentin, Sébastien et Nathalie.

Mes parents et amis, pour leur soutien constant et leurs encouragements.

Résumé

La fraude sur les marchés numériques est un problème pour la communauté de la cybersécurité et les entreprises de commerce électronique. Elle entraîne une augmentation des plaintes et menace la confiance des consommateurs. C'est dans ce contexte qu'une solution est élaborée pour détecter les fausses petites annonces de vente, de manière fiable et efficace. La solution détaillée dans cette recherche exploratoire vise à surmonter les limites des systèmes de détection réactifs en adoptant une approche proactive, qui combine les analyses qualitatives et quantitatives pour détecter des signes de fraude. Pour ce faire, des indicateurs sont repérés et utilisés pour établir la probabilité indiciaire de fraude d'une annonce. Le modèle proposé s'appuie sur « l'élaboration de savoir-faire actionnables » selon Marie-José Avenier & Christophe Schmitt (2007) et sur « la méthodologie indiciaire de la trace » d'Olivier Ribaux (2023). Il vise à développer une théorie capable de reconnaître les annonces frauduleuses avant qu'elles ne causent plus de dommage. L'approche méthodologique comprend 6 entretiens avec 9 spécialistes de la lutte contre la cybercriminalité, ainsi qu'une étude de cas réalisé sur un échantillon de 2 166 annonces collecté sur Facebook Marketplace. Les résultats démontrent l'efficacité du modèle à détecter les probabilités indiciaires de fraude, et l'adoption d'un tel modèle ouvre la voie à une gouvernance décentralisée du risque numérique. Ainsi, ce travail ambitionne de participer au renforcement de la sécurité du commerce en ligne, à l'amélioration de l'action de sécurité, et au soutien d'un bien-être numérique durable.

Table des matières

Remerciements.....	1
Résumé.....	2
Abréviations.....	5
Introduction.....	7
1. Question de recherche.....	8
1.1 Sujet d'étude.....	8
1.2 Présentation des données de la situation.....	10
1.3 Contexte théorique.....	12
2. Méthodologie.....	16
2.1 Connaissance.....	16
2.2 Méthode mixte.....	17
2.3 Échantillonnage, collecte et analyse des données.....	17
3. Littérature.....	21
3.1 Nature des annonces frauduleuses.....	21
3.2 Détection de la fraude.....	22
3.3 Profils, stratégies et recommandations.....	24
4. Théorie.....	26
4.1 Entretiens exploratoires.....	26
4.2 Élaboration de la théorie.....	30
4.3 Vérification de la théorie.....	31
5. Étude de cas.....	38
5.1 Collecte de cas de fraudes et de non-cas.....	38
5.2 Approche qualitative : confrontation du modèle.....	38
5.3 Approche quantitative : performance du modèle.....	40
5.4 Discussion.....	41
Conclusion.....	42
Bibliographie.....	44
Annexes.....	52
Annexe 1. Indices de la fraude.....	52
Annexe 2. Guide d'entretien.....	54
Annexe 3. Directives du fichier robots.txt de FM.....	56
Annexe 4. Métriques des tests de performance.....	57
Annexe 5. Paramètres de configuration du modèle.....	58
Annexe 6. Vérification de la théorie : données collectées.....	59
Annexe 7. Vérification de la théorie : analyse descriptive.....	60
Annexe 8. Vérification de la théorie : analyse de performance.....	61
Annexe 9. Étude de cas : données collectées.....	63
Annexe 10. Étude de cas : statistiques descriptives.....	64
Annexe 11. Étude de cas : performance prédictive.....	65
Annexe 12. Fichiers externes.....	67

Index des tableaux

Tableau 1 : Entités composant la communauté de la sécurité (Dupont, 2024, p. 146)....13

Tableau 2 : Entretiens exploratoires.....18

Tableau 3 : Cadre de l'analyse statistique descriptive.....20

Tableau 4 : Cadre de l'analyse statistique inférentielle.....21

Tableau 5 : Paramètres de configuration des tests empiriques.....31

Tableau 6 : Échantillonnage du modèle théorique.....34

Tableau 7 : Répartition indiciaire de l’échantillon par le modèle théorique.....35

Tableau 8 : Test de performance du modèle théorique.....35

Tableau 9 : Matrice de confusion du modèle théorique.....35

Tableau 10 : Répartition des signes du modèle théorique.....36

Tableau 11 : Répartition des indicateurs de l’étude de cas.....39

Tableau 12: Test de performance du modèle de détection.....40

Tableau 13: Matrice de confusion du modèle de détection.....40

Index des figures

Figure 1 : Modes d’interdépendances intraspécifiques et interspécifiques des trois communautés de l’écosystème du cybercrime (Dupont, 2024, p. 51).....12

Figure 2 : Cadre de référence pour l’élaboration de « savoirs actionnables » fondé sur le savoir-faire des praticiens (Avenier & Schmitt, 2007, p.153).....14

Figure 3 : Les trois temps de l’investigation (Ribaux, 2023, p. 204).....15

Abréviations

AUC	Area under curve
BERT	Bidirectional Encoder Representations from Transformers
CaaS	Crime-as-a-service
CPS	Code Pénal Suisse
CNN	Convolutional Neural Networks
CSV	Comma-Separated Values
DFAE	Département fédéral des affaires étrangères
EUROPOL	European Union Agency for Law Enforcement Cooperation
ESC	École des sciences criminelles
FM	Facebook Marketplace
GAFa	Google, Apple, Facebook et Amazon
HTTP	HyperText Transport Protocol
IA	Intelligence Artificielle
IAG	Intelligence Artificielle Générative
ILCE	Institut de lutte contre la criminalité économique
LDA	Loi fédérale sur le droit d’auteur et les droits voisins
IP	Internet Protocol
LPD	Loi sur la protection des données
LSTM	Long Short-Term Memory
MLP	Multilayer Perceptron
MySQL	My Structured Query Language
NLP	Natural Language Processing
OFS	Office Fédéral de la Statistique
ONG	Organisation non gouvernementale

Polcant	Police cantonale vaudoise
POFR	Police cantonale neuchâteloise
POGE	Police cantonale de Genève
PONE	Police cantonale neuchâteloise
POVS	Police cantonale valaisanne
RGPD	Règlement général sur la protection des données
RoBERTa	Robustly Optimized BERT Approach
ROC	Receiver Operating Characteristic
RNN	Recurrent Neural Network
RS	Recueil Systématique
SVM	Support-Vector Machine
TF-IDF	Term Frequency-Inverse Document Frequency
TOS	Terms Of Service
UE	Union européenne
VoIP	Voice over IP
XGBoost	eXtreme Gradient Boosting
WWW	World Wide Web

Introduction

Depuis la création du WWW par Tim Berners-Lee, l'essor du numérique ne cesse de transformer les interactions commerciales. Malencontreusement, il a également créé des opportunités à de nouvelles formes de criminalité. Parmi celles-ci, la fraude aux petites annonces s'avère être une menace insidieuse, touchant une large population et posant un défi majeur aux acteurs de la cybersécurité. La détection de cette fraude se révèle complexe en raison de sa portée internationale, et des méthodes utilisées par les cybercriminels, qui exploitent systématiquement les vulnérabilités des systèmes de sécurité existants. Actuellement, les méthodes de détection classiques se révèlent insuffisantes, car elles reposent sur des schémas de fraude connus et peinent à s'adapter aux nouvelles stratégies criminelles. Ces méthodes, qui se limitent à des approches réactives, se décomposent dans leur mise en application et s'avèrent peu flexibles. Elles offrent une réponse souvent tardive et ponctuelle, face à une délinquance en constante mutation. C'est dans ce contexte que cette recherche propose un modèle de détection fondé sur la reconnaissance et l'identification d'indicateurs spécifiques aux fausses petites annonces de vente. L'approche méthodologique utilise une démarche mixte, combinant une analyse thématique de 6 entretiens exploratoires, et une analyse descriptive de 315 annonces suspectes, afin d'identifier les signes distinctifs de la fraude et établir une théorie fiable. Une étude de cas est ensuite réalisée sur 2 166 annonces pour tester et valider la mise en œuvre du modèle issu de la théorie. Avec un AUC-ROC de 0,98, les résultats du test de performance démontrent l'efficacité du modèle à détecter une probabilité indiciaire de fraude. Ainsi, ce travail explore une nouvelle approche de gouvernance du risque numérique, en promouvant une gestion collaborative fondée sur un indice. L'adoption du modèle permettant d'envisager une gouvernance décentralisée, il offre des possibilités d'améliorer la sécurité et de favoriser un bien-être numérique à long terme. En résumé, cette recherche propose d'explorer un modèle actionnable qui permet de fournir à la communauté industrielle et aux responsables de la cybersécurité un outil opérationnel et efficace.

1. Question de recherche

Comment détecter les fausses petites annonces de vente, de manière efficace et fiable ?

1.1 Sujet d'étude

Les fausses petites annonces de vente publiées sur les plateformes de commerce en ligne constituent une porte d'entrée vers diverses activités criminelles, notamment des escroqueries (art. 146 CPS, RS 311.0) ou du blanchiment d'argent (art. 305bis CPS, RS 311.0). Ces infractions ciblent toujours l'argent des victimes, et elles peuvent engendrer des préjudices considérables (Rossy, 2024). En 2023, l'OFS (2023) indique que 79,8 % du total des escroqueries enregistrées sont numériques. Et un taux d'élucidation des infractions signalées de seulement 18,7 % est reporté, alors que ces escroqueries représentent à elles seules 69,1 % de la criminalité numérique totale (OFS, 2023). Considérant qu'environ 15 % du commerce de détail est désormais réalisé par Internet (DFAE, 2023), la multiplication de ces fraudes, en plus de l'impact social, peut finir par altérer la confiance des consommateurs dans le commerce numérique. Ces chiffres montrent non seulement l'ampleur du phénomène, mais aussi l'impact de ces infractions.

Comment détecter les fausses petites annonces de vente ?

La détection des petites annonces frauduleuses repose sur l'identification de signes et d'indices présents dans les contenus publiés. Ces indicateurs, que ce soient des motifs récurrents ou des anomalies, permettent de reconnaître des signes de fraude en lien avec les modes opératoires et les intentions malveillantes. Actuellement, de nombreuses sociétés proposent l'utilisation de modèles automatisés capables d'identifier des schémas frauduleux (Akamai, s. d.; Comply Advantage, s. d.; Confluent, s.d.; Fingerprint, s. d.; Imperva, s. d.). Cependant, ces modèles se basent principalement sur des schémas criminels connus, et leur capacité à interpréter de nouvelles configurations repose souvent sur l'ajustement de schémas existants (Ribaux, 2023, p. 479). Bien que ces outils apportent un certain soutien à la sécurité, ils montrent leurs limites dans une perspective proactive. En effet, la forte compétitivité du secteur complique les coopérations, ceci en raison de la crainte que de telles mesures de sécurité publique n'affectent la rentabilité commerciale (Dupont, 2024, p. 46). Face à cette limite, il est nécessaire de réfléchir à des modèles de détection proactifs, capables de mener des

analyses indépendantes, intégrant des algorithmes aptes à identifier des schémas non encore répertoriés. C'est en combinant des appréciations quantitatives et qualitatives, et en adoptant une approche fondée sur des savoirs actionnables qu'il est proposé de renforcer la détection des fausses petites annonces de vente.

Comment s'adapter à l'évolution des modes opératoires ?

Dans un contexte où les modes opératoires évoluent rapidement, une actionnabilité des savoirs permet de s'adapter à l'évolution de la cybercriminalité. Cela signifie que les connaissances ne doivent pas seulement être théoriques ou statiques, mais qu'elles doivent s'appliquer et viser des solutions concrètes. Une telle approche, qui vise à « entrer en résonance avec les préoccupations effectives », ambitionne de comprendre les situations problématiques, d'élaborer une vision stratégique, et de faire changer les comportements (Avenier & Schmitt, 2007b, p. 149). L'objectif consiste à influencer les agissements et à renforcer les pratiques de sécurité (détection de la fraude), ou à dissuader les criminels d'agir, grâce à des mesures proactives (indice de fraude). Car une communauté criminelle qui s'adapte constamment aux systèmes de détection pose un défi permanent à la communauté de la sécurité. Et, cette dernière est contrainte d'ajuster continuellement ses stratégies. En réponse de quoi, les modèles de détection doivent être évolutifs et capables d'adaptations, en fonction de l'information et des tendances observées.

Comment anticiper les tendances criminelles ?

L'anticipation des tendances criminelles passe par l'intégration « d'une surveillance systématique » et « d'une analyse détaillée des problèmes » (Ribaux, 2023, p. 484). La veille et les analyses prédictives facilitent alors la reconnaissance des modes opératoires frauduleux, mais, dans certains cas, des statistiques simples ou une visualisation de données adaptée peuvent suffire pour déceler les anomalies les plus flagrantes (p. 481). De nombreuses méthodes ont été explorées pour anticiper des tendances criminelles, mais les résultats restent modestes, en raison de la fragmentation des données utilisées par ces systèmes complexes (Albertetti cité par Ribaux, p. 484). Pour détecter efficacement de nouvelles menaces, les modèles de détection ne peuvent se limiter à une approche uniquement centrée sur la technologie ou l'observation des données. Une ouverture aux perspectives contextuelles s'impose. Car, analyser le comportement criminel en adoptant exclusivement sa propre grille de référence peut en effet introduire

des biais importants, surtout lorsque ces comportements varient selon le contexte (économique, culturel, social, juridique, etc.). Comme le souligne Moinet (2009), « la plus grande dérive étant d'analyser ou de prévoir le comportement de l'autre avec sa propre grille de lecture » (p. 59). Ainsi, prédire les évolutions criminelles dans le domaine du numérique exige une approche collaborative entre différentes entités. Celles-ci incluent les plateformes, les organismes gouvernementaux, et les entreprises, afin de mieux saisir l'aspect écosystémique de ce type de délinquance (Dupont, 2024).

1.2 Présentation des données de la situation

Une menace économique et sociétale

Directement ou indirectement, la détection des fraudes de vente en ligne concerne 67 % de la population suisse des plus de 15 ans (OFS OMN, 2023). Il est important de protéger les personnes vulnérables contre les escroqueries en ligne, car celles-ci peuvent entraîner des pertes financières et émotionnelles significatives, non seulement pour les victimes, mais aussi pour la société dans son ensemble. Avec l'importance croissante de l'économie numérique, les répercussions sociétales de la fraude en ligne sont devenues bien réelles (Aebi et al., 2022). Cette forme de délinquance affecte les individus et, à long terme, elle érode la confiance des consommateurs. Et, bien que les préjudices individuels restent faibles et affectent des individus issus de toutes les classes sociales, les fraudes aux petites annonces touchent plus particulièrement les personnes à faible revenu (2022). En exploitant la naïveté et l'inexpérience, les cyberdélinquants ciblent en préférence les individus peu familiers avec les mécanismes de sécurité en ligne. Et parfois, les victimes alimentent involontairement de nouvelles escroqueries en fournissant aux criminels des informations personnelles sensibles. La fracture numérique est alors un facteur de victimisation, et certains individus passent du statut de victimes d'escroquerie à celui de mules financières, pour finir par se retrouver aux prises avec la justice sans en avoir conscience (Grandjean et al., 2022; Greter, 2020).

Une délinquance à faible impact, mais à fort volume

Actuellement, les institutions éprouvent de grandes difficultés à prendre en charge « la délinquance à faible impact individuel, mais à très fort volume qui caractérise la révolution numérique » (Dupont, 2024, p. 118). Et, bien que chaque cas de fraude n'entraîne « que » des pertes relativement modestes, leur prolifération représente un

problème d'une ampleur considérable. Car, contrairement aux exploits technologiques souvent représentés dans les productions hollywoodiennes (WarGames, 1983), les auteurs de petites annonces frauduleuses s'orientent vers des escroqueries à grande échelle. Ils publient des centaines d'annonces à partir de différents comptes, en copiant et collant le même contenu (Al-Rousan et al., 2020). Individuellement, ces délits impliquent des montants faibles, cependant, mis à l'échelle, ils entraînent des pertes financières cumulatives importantes, avec des répercussions humaines encore difficiles à évaluer. Et, les conséquences de ces préjudices, en dessous des limites de toutes considérations, posent des problèmes difficiles à traiter pour le système judiciaire (accumulation de pertes économiques invisibles, érosion de la confiance dans le système de protection, isolement et impact psychologique sur les victimes, saturation des ressources judiciaires, banalisation de ce type de criminalité, automatisation de la délinquance à grande échelle, externalisation du fardeau sur les victimes, etc.) (Dupont, 2014).

Une pluralité des acteurs de la cybersécurité

La lutte contre la cybercriminalité est fragmentée entre de multiples entités, et les acteurs de la cybersécurité sont nombreux et diversifiés. Chacun d'eux dispose de fonctions et de ressources qui sont cloisonnées selon les spécificités de leur rôle. Contrairement à la sécurité de l'espace public traditionnel (monopole de l'action de police), la sécurité de l'espace public numérique est assurée par une multitude d'acteurs issus de diverses entités (Dupont, 2024). Pour Dupont, la nécessité d'une approche concertée et coordonnée est mise en évidence par la « multilatéralisation de la sécurité » de Bayley et Shearing (2001). Cette théorie souligne l'importance d'une collaboration inévitable entre les « entités prescriptrices » et les « entités prestataires » de sécurité (Tableau 1), collaboration dont dépend la lutte contre le cybercrime. C'est cette fragmentation des responsabilités qui crée un terrain favorable aux cybercriminels. Ceux-ci adaptent leurs méthodes en fonction des nouvelles technologies ou des contre-mesures adoptées, et cela génère un déséquilibre entre les moyens de défense et les menaces émergentes (Dupont, 2024, p. 133). Dans le cadre de la fraude aux fausses petites annonces en ligne, la responsabilisation et la participation des intermédiaires sont essentielles. En effet, bien que les plateformes jouent un rôle central dans la diffusion des annonces frauduleuses, elles sont aussi en première ligne pour mettre en œuvre des systèmes de détection proactifs. La coopération des plateformes avec les

autres acteurs de la cybersécurité est donc nécessaire pour renforcer la protection de l'espace public numérique et développer une réponse adaptée face à des menaces de plus en plus évoluées.

1.3 Contexte théorique

L'écosystème du cybercrime

Dans son livre *La cybercriminalité* (2024), Benoît Dupont adopte une perspective écosystémique pour examiner l'espace numérique, également connu sous le nom de « cyberspace ». Il décrit le cybercrime comme un écosystème dynamique, où interagissent diverses entités qui composent cet environnement (organisations, individus, équipements, applications et normes).




Figure 1 : Modes d'interdépendances intraspécifiques et interspécifiques des trois communautés de l'écosystème du cybercrime (Dupont, 2024, p. 51)

Dans son ouvrage, Dupont distingue trois grands groupes au sein de cet écosystème : la communauté de la sécurité, la communauté industrielle et la communauté délinquante (Figure 1). Les entités de ces communautés interagissent selon trois modes relationnels principaux : la compétition, la prédation et la coopération. L'écosystème est façonné par

des interconnexions constantes, ce qui favorise la prolifération des délits numériques en raison de la rapidité d'évolution des technologies et des lacunes persistantes dans les systèmes de défense. Selon Dupond (2024), cette approche écosystémique permet de guider l'élaboration d'un cadre intégrateur pour la cybersécurité, où l'écosystème numérique est utilisé comme un ciment théorique pour mieux comprendre et anticiper les dynamiques du cybercrime.

<i>Entités prescriptrices</i>	Organisations internationales, autorités régulatrices, entreprises du numérique, organismes de normalisation, compagnie d'assurances.
<i>Entités prestataires</i>	Entreprises de cybersécurité, ONG et groupes de réflexion, associations professionnelles de certification, chercheurs académiques et indépendants, membres de la société civile.

Tableau 1 : Entités composant la communauté de la sécurité (Dupont, 2024, p. 146)

L'élaboration de savoirs pour l'action

C'est par l'intermédiaire de leur recueil *La construction de savoirs pour l'action* (2007), que Marie-José Avenier et Christophe Schmitt proposent un cadre de référence pour l'élaboration de savoirs actionnables fondés sur le savoir-faire des praticiens (Figure 2). Le cadre proposé s'articule autour de cinq processus entrelacés : la conception du canevas de recherche, la construction de savoirs actionnables locaux, l'élaboration de savoirs actionnables génériques et l'activation de ces savoirs (p. 153). La notion de savoirs actionnables fait alors référence à « un savoir à la fois valable et pouvant être mis en action dans la vie quotidienne des organisations » (Argyris cité par Avenier & Schmitt, p. 147).

Une telle approche est particulièrement pertinente pour le développement d'outils de détection proactive, pour deux raisons. Premièrement, elle favorise la mise en action des savoirs, en les mobilisant pour susciter le questionnement, la réflexion, et l'action créative (p. 148). Cet aspect est essentiel dans le cadre d'une démarche exploratoire, car il incite à la recherche de solutions nouvelles et adaptatives. Deuxièmement, cette approche valorise l'utilisation de savoirs empiriques, issus de l'observation des pratiques, pour concevoir des outils et des stratégies opérationnels. Cela met en avant la nécessité de réactivité et d'adaptation des modèles de détection face à un environnement criminel en constante évolution. Ainsi, cette démarche pragmatique insiste sur des

savoirs qui ne sont pas seulement théoriques, mais qui doivent être éprouvés et validés dans des contextes pratiques, garantissant leur efficacité et leur applicabilité (Avenier & Schmitt, 2007a).




Figure 2 : Cadre de référence pour l'élaboration de « savoirs actionnables » fondé sur le savoir-faire des praticiens (Avenier & Schmitt, 2007, p.153)

La méthodologie indiciaire

L'ouvrage *De la police scientifique à la traçologie* (2023), d'Olivier Ribaux, propose une méthodologie indiciaire qui constitue une référence de l'action d'investigation. Cette dernière repose sur un processus en trois temps (Figure 3) : la production de la trace (enregistrement et publication des annonces), l'investigation des signes (capture et enregistrement des descriptions publiées sur la plateforme de vente) et la reconstruction des activités criminelles (interprétation des signes et indices de fraude).




Figure 3 : Les trois temps de l'investigation (Ribaux, 2023, p. 204)

Un des objectifs principaux du modèle de détection est de collecter les traces numériques en repérant les indicateurs conduisant à la reconnaissance des signes de fraude. En accumulant ces indices, il devient alors possible de déterminer, de manière de plus en plus précise, la probabilité qu'une annonce soit frauduleuse. La méthodologie indiciaire permet de poser les bases d'un modèle de détection reposant sur des critères objectifs et mesurables, facilitant l'évaluation des probabilités de fraude. Une telle

méthode offre également la structure pour un modèle proactif, dans lequel les fonctions d'acquisition et de détection s'alignent avec les objectifs de ce travail (p. 410). Pour toutes ces raisons, qu'il s'agisse des phases d'investigation et de reconstruction, ou de l'intégration de cette méthodologie dans des processus de veille, le renseignement par la trace et la méthodologie indiciaire présentent un cadre de référence fiable pour un modèle de détection efficace.

2. Méthodologie

2.1 Connaissance

Cette recherche met en lumière trois indicateurs, et plusieurs signes ou indices pour reconnaître des petites annonces frauduleuses. Il met également en application une méthodologie pour détecter et identifier les fausses petites annonces de vente. En complément, l'approche proposée offre une compréhension holistique du phénomène des annonces frauduleuses. Ceci, grâce aux entretiens exploratoires avec les praticiens et à l'analyse des données collectées sur la plateforme FM.

Ainsi, plusieurs aspects du phénomène sont portés à l'attention. On compte notamment : la complexité des interactions entre les différentes communautés ; la diversité des acteurs de la cybersécurité ; l'évolution constante des modes opératoires criminels ; et l'influence des méthodes commerciales sur les processus de détection. Pour cela, la représentation du problème issu de cette recherche offre la possibilité de mieux appréhender les stratégies, et d'adapter les mesures de sécurité aux réalités opérationnelles de la lutte contre la fraude.

Par exemple, les plateformes de vente en ligne peuvent s'appuyer sur les résultats de ce travail pour intégrer une signalétique d'alerte. En outre, l'indice de fraude élaboré peut être proposé comme élément central de la prévention, et comme soutien au transfert de compétences concernant les dangers numériques. À propos de la gouvernance des risques numériques, les plateformes et les autorités peuvent conjointement se servir de la probabilité indiciaire de fraude pour mieux surveiller et réguler l'espace numérique.

En définitive, un modèle tirant parti des connaissances développées par cette recherche contribue à renforcer la sécurité en construisant un cadre de bien-être numérique durable.

2.2 Méthode mixte

L'approche qualitative et l'approche quantitative jouent des rôles complémentaires dans la détection de la fraude. L'approche qualitative permet une exploration du phénomène, pour comprendre quelles sont les stratégies utilisées par les fraudeurs et quels indicateurs sont à utiliser pour l'analyse des informations. Elle permet de poser les fondations du modèle, dans un premier temps. Dans un second temps, l'approche quantitative teste le modèle sur des données réelles, et permet de mesurer sa fiabilité. Comme le soulignent Fortin et Gagnon (2022) : l'approche qualitative offre la possibilité de mieux comprendre le phénomène dans sa globalité, pour élaborer un modèle efficient ; l'approche quantitative permet, quant à elle, de tester et de valider de manière objective le modèle développé, en s'assurant qu'il peut être fiable.

Pour ces raisons, le plan d'ensemble de la recherche se fonde sur un devis séquentiel exploratoire. Ce devis exploratoire commence par la collecte et l'analyse de données qualitatives (4.1) dont les résultats structurent la collecte et l'analyse des données quantitatives (4.3). L'objectif est que la phase qualitative puisse viser à développer un modèle théorique (4.2), la phase quantitative permet d'en confirmer, infirmer ou modifier certains éléments (p. 216).

Le produit mixte résultant consiste en une collecte/analyse de données quantitative qui est structurée par des résultats qualitatifs. Cette stratégie permet d'atteindre les objectifs suivants : développer une typologie (indice de fraude) et une taxonomie (probabilité indiciaire de fraude) ; créer un instrument (reconnaissance des signes de fraude) et l'utiliser pour une mesure (calcul d'un indice de fraude) ; valider un instrument de détection écologique de la fraude (indicateurs), puis la détection de construits (indices) ; construire un cadre conceptuel (modèle théorique) et le tester (modèle de détection) (p. 216).

2.3 Échantillonnage, collecte et analyse des données

2.3.1 Sources des données

Pour recruter des praticiens membres de la communauté de la sécurité, une liste de participants engagés dans la lutte contre la cybercriminalité a été établie. Grâce à l'échantillonnage par boule de neige (Johnston & Sabin, 2010), et à un échantillonnage

au jugé (Etikan, 2016), il fut possible de contacter huit praticiens issus des départements cyber des cinq principales polices cantonales de Suisse romande.

En parallèle, et suite à un entretien préparatoire avec des experts de l’ILCE, la plateforme de Facebook Marketplace (FM) a été choisie comme source de données quantitatives. Ce choix repose sur le fait que FM est accessible depuis le réseau social Facebook, qui compte une audience de trois milliards d’utilisateurs, ce qui en fait une plateforme largement utilisée (Mokhberi et al., 2024; Statita, 2024).

2.3.2 Collecte des données

Entretiens exploratoires

Six entretiens exploratoires ont été menés, impliquant divers profils professionnels : enquêteur judiciaire, analyste criminel, responsable de groupe et chercheur. La décision est prise de privilégier les entretiens en personne, afin de valoriser l’approche exploratoire du dialogue et de faciliter la captation des informations non verbales. Un guide d’entretien (Annexe 2) a été rédigé afin d’établir les bases thématiques des sujets à aborder et des questions importantes à poser.

Entretiens	1	2	3	4	5	6
Dates	02/08	14/08	22/08	29/08	03/09	06/09
Entités	PONE	Polcant	POFR	POVS	POVS	ESC
Répondants	Sébastien	Jules	Maël	Francis	Patrice	Quorentin
	Gilles	Alain	Eric			

Tableau 2 : Entretiens exploratoires

La conduite des entretiens s’est effectuée à trois niveaux (les questions, les relances, l’observation) dans le but d’analyser les émotions des répondants (Francey et al., 2023). Pour recueillir les données, la méthode de l’entretien semi-structuré est utilisée, car elle permet de mettre en lumière le sens que la personne interrogée accorde à certains éléments (Rondeau & Paillé, 2016; Sauvayre, 2013). L’entretien semi-structuré offre aussi des informations sur le ressenti des personnes via des expressions non verbales, telles que le ton de la voix ou le langage corporel (Broustau et al., 2012; Opdenakker, 2006).

Les entretiens doivent aborder une liste de thèmes identifiés en amont (Romelaer, 2005), tout en laissant de la place à l'émergence de nouveaux thèmes au cours du discours (Jackson et al., 2007). À cet effet, une grille (Annexe 2) est élaborée pour identifier les thématiques à explorer et structurer le fil conducteur (Hancock et al., 2001). Cette grille comporte trois axes principaux : les petites annonces frauduleuses, les fausses annonces de ventes et les moyens de détection. L'objectif de la recherche est expliqué à chaque participant, ainsi que le caractère anonyme et enregistré de l'entrevue, avec consentement préalable obtenu par la signature d'un formulaire de consentement (Annexe 12). L'intérêt de mener l'entretien dans un espace calme et confortable a été pris en compte (Hancock et al., 2001). Finalement, il est important de souligner qu'étant donné l'échantillon de neuf individus, ces résultats ne sont pas généralisables (Flick, 2022).

Extraction manuelle de données web

Concernant les données quantitatives, la méthode d'acquisition de données utilisée est connue sous le nom de *manual scraping* (extraction manuelle de données web). Cette technique consiste à récupérer des informations diffusées sur Internet (HTTP), par des interactions manuelles réalisées à partir d'un navigateur (Google Chrome). Deux étapes ont été mises en place, la première pour réunir une liste de références, comprenant des annonces sélectionnées à partir de l'application de recherche de FM. La seconde, pour enregistrer manuellement les données à extraire (titre, prix, description, pseudonyme, date de création du profil). Ces informations sont ensuite enregistrées, avant d'être traitées et intégrées à une base de données MySQL et ensuite sauvegardées au format CSV dans un fichier protégé.

La collecte de données sur des sites web soulève diverses préoccupations, notamment d'ordre technique, juridique et éthique (Mancosu & Vegetti, 2020). Concernant la conformité avec la LPD (RS 235.1) et le RGPD (UE 2016/679), l'extraction s'est limitée aux données publiques et aucune donnée personnelle (Art. 5 LPD, RS 235.1) n'a été collectée. Pour assurer le respect des conditions d'utilisation (TOS) de FM, une attention particulière fut prise de respecter les conditions détaillées dans le fichier « robots.txt » (Annexe 3). De plus, en raison des droits d'auteur potentiellement applicables aux données recueillies, conformément à la LDA (RS 231.1), aucune donnée collectée ne sera réutilisée. Toutes les données sont supprimées dès la fin de la recherche, avec les enregistrements audio des entretiens.

2.3.3 Procédure d'analyse

Analyse thématique des données qualitatives

Pour analyser les données qualitatives, une analyse thématique de contenu est choisie. Cette approche permet de condenser les données textuelles brutes en établissant des liens entre les objectifs de recherche et les conclusions tirées des données, tout en développant un modèle basé sur des catégories émergentes (Thomas, 2006). Selon Blais et Martineau (2006), relire les entretiens permet d'identifier dans le récit des catégories qui sont ensuite mises en lien, et illustrées par des « verbatims » (extraits mot pour mot des entretiens). Pour appliquer, cette approche, chaque entretien est tout d'abord analysé verticalement, avec des points clés soulignés et les premières catégories sont définies. Ensuite, une analyse horizontale compare les entretiens entre eux, identifiant des points de convergence et de divergence, ainsi que la manière dont ces derniers se chevauchent, se renforcent, s'opposent ou se complètent (Francey et al., 2023).

Analyse descriptive des données quantitatives

L'analyse statistique descriptive vise à exprimer, par des méthodes mathématiques, les caractéristiques principales des données, en synthétisant l'information pour n'en révéler que l'essentiel (Anderson et al., 2015). Elle dresse un tableau préliminaire des informations et des tendances perceptibles dans les données des deux échantillons collectés (Annexe 6, Annexe 9). La population des deux analyses effectuées (vérification de la théorie et étude de cas) est constituée de l'ensemble des annonces de FM, et chaque annonce représente une unité statistique. Les caractères analysés incluent deux variables quantitatives discrètes (P, D) et une variable continue (S).

Population	Échantillon	Individu	Caractère	Modalité
FM	vérification, étude de cas	annonce	prix (P), date (D), similarité (S)	PRICE_SCORE, DATE_SCORE, SIM_SCORE, INDEX

Tableau 3 : Cadre de l'analyse statistique descriptive

C'est l'indice de Jaccard (1902) qui est utilisé pour mesurer la similarité entre les individus. Défini comme le rapport entre l'intersection et l'union de deux ensembles de mots, l'indice est une valeur comprise entre 0 et 1, où 1 signifie que les deux individus sont identiques (Costa, 2021). Simple à implémenter, il s'avère efficace pour comparer

la similarité entre deux ensembles d'éléments. À titre d'information, pour la détermination des seuils de similarité, des outils de détection de plagiat comme Turnitin (2024) utilisent des seuils de 0 à 15 % pour une faible similarité, 15 à 30 % pour une similitude nécessitant un examen plus approfondi, et de plus 30 % pour une forte similarité (Meo & Talha, 2019).

Analyse inférentielle des données quantitatives

L'analyse statistique inférentielle constitue la dernière étape cruciale pour valider le modèle de détection. L'algorithme d'apprentissage supervisé *Random Forest* (Breiman & Cutler, s. d.), est retenu pour établir un modèle prédictif capable de classer les annonces en deux catégories : celles ayant une probabilité indiciaire « défavorable » et celles présentant une probabilité indiciaire « acceptable » . Cet algorithme est entraîné sur un ensemble d'annonces (*dataset*) dont la variable CIBLE (*target*) représente la valeur à prédire. Les variables de prix, la date de création du profil et la description de l'annonce constituent les facteurs (*feature*) influençant la variable CIBLE (Saint-Cirgue, 2019). Pour valider la fiabilité du modèle, des mesures standards de performance sont utilisées : précision, sensibilité, spécificité, taux d'erreur, score F1 (Annexe 1). Ces évaluations fournissent un aperçu global des capacités du modèle à détecter les annonces frauduleuses et à prédire efficacement la fraude (Khichane, 2021; Powers, 2020).

Modèle	Paramètres	Méthode d'apprentissage
Random Forest	n_estimators = 100	Stratified K-Fold Cross-Validation
Classifieur	random_state = 42	

Tableau 4 : Cadre de l'analyse statistique inférentielle

3. Littérature

3.1 Nature des annonces frauduleuses

Selon la littérature, les petites annonces frauduleuses revêtent de nombreuses formes et servent des objectifs variés. Par exemple, en 2020, 78 % des mules financières ont été engagées via de fausses annonces d'offres d'emploi, utilisées pour exploiter les victimes et les impliquer dans des activités illégales (Akram et al., 2024; Al-Rousan et al., 2020; Greter, 2020; Jacquart et al., 2021; Rizka, 2024). Les petites annonces frauduleuses

servent également de vecteurs vers des sites de *phishing*, tandis que le *malvertising* (publicités malveillantes) constitue une variante utilisant des publicités apparemment légitimes pour masquer des liens vers des sites frauduleux ou diffuser des *malware* (logiciels malveillants) (Kumari & Sharma, 2024; Saumya & Singh, 2022; Shahariar et al., 2019; Shaukat et al., 2023).

Pour masquer leur identité, attirer les internautes et échapper aux systèmes de détection, les fraudeurs déploient des tactiques variées. Celles-ci incluent des interactions et des correspondances apparemment légitimes ainsi que des techniques sophistiquées, comme le *domain spoofing* et le *ad stacking*. Ces méthodes permettent aux criminels de manipuler les utilisateurs et de déjouer les protections de sécurité, redirigeant ainsi les victimes vers des sites frauduleux (Ago Thérèse Tanoh, 2023; Alzghoul et al., 2024; Malik et al., 2024; McCormick & Eberle, 2013). Comme le souligne Wall (2015), Internet facilite les escroqueries en ligne, et les petites annonces frauduleuses constituent un exemple de *cyber-enabled crimes*. Cette nouvelle délinquance représente une transformation des escroqueries traditionnelles, l'utilisation d'Internet permettant d'étendre les fraudes à grande échelle (Rossy & Borisova, 2020).

3.2 Détection de la fraude

Indicateurs de fraude

Les indicateurs de fraude relevés dans la littérature incluent divers éléments permettant d'identifier les petites annonces frauduleuses. Les offres sont souvent très attractives, mais floues, avec des descriptions imprécises ou des prix inhabituellement bas pour attirer rapidement les victimes (Al-Rousan et al., 2020; Alzghoul et al., 2024). Les erreurs linguistiques, comme les fautes d'orthographe flagrantes, les répétitions textuelles inhabituelles et les phrases incohérentes, sont également fréquentes et révèlent la nature parfois automatisée ou peu soignée de ces annonces (Al-Sayyed et al., 2023; Ben Abdallah & Boukadi, 2023; EUROPOL, 2024; Mokhberi et al., 2024).

Le contenu visuel peut également être suspect, avec des images souvent de mauvaises qualités ou dérobé d'autres sources, ce qui renforce le caractère trompeur de l'annonce (Al-Rousan et al., 2020; Alzghoul et al., 2024). Quant aux indicateurs de source et d'authenticité, les fraudeurs copient souvent des annonces légitimes et usurpent des informations, rendant ces annonces particulièrement trompeuses (Al-Rousan et al.,

2020; McCormick & Eberle, 2013). Les sites web contrefaits et les liens malveillants constituent aussi des signes de fraude. Les annonces redirigent vers des sites frauduleux à travers des liens malveillants ou des noms de domaines douteux pour collecter des informations personnelles (CrowdStrike, 2024; Kumari & Sharma, 2024).

Le profil des utilisateurs et leurs incohérences sont également révélateurs. Les fraudeurs masquent leur identité en utilisant des comptes créés récemment, souvent sans historique ou avec des informations incomplètes (Mokhberi et al., 2024; Washha et al., 2017). L'utilisation de technologies difficiles à tracer, telles que la VoIP ou des méthodes de paiement alternatives comme PayPal ou Western Union, complique également la traçabilité des délinquants (Alzghoul et al., 2024).

Les comportements et les interactions sur les plateformes en ligne sont aussi révélateurs. Car les fraudeurs cherchent souvent à déplacer la communication vers des applications privées (comme WhatsApp) pour échapper aux contrôles des plateformes et éviter la traçabilité (Grandjean et al., 2022; Koua et al., 2015). Lors des échanges, des réponses incohérentes, des demandes d'aide financière soudaine, ou des récits émotionnels visant à manipuler les victimes sont aussi des indicateurs à prendre en compte (Grandjean et al., 2022; Greter, 2020; Jacquart et al., 2021).

Enfin, les évaluations et la réputation sociale jouent un rôle significatif. Les commentaires d'autres utilisateurs obtenus par le *crowdsourcing* sont des indicateurs précieux pour identifier les annonces frauduleuses, car elles reposent sur l'expérience de la communauté (Nanath & Olney, 2023). Mokhberi et al. (2024) soulignent l'importance d'examiner les caractéristiques des utilisateurs, les échanges de messages, et l'historique des transactions pour détecter efficacement la fraude.

Méthodes de détection

De manière générale, de nombreuses études proposent des méthodes pour améliorer la détection de la fraude en ligne. Ben Abdallah (2023), par exemple, recommande l'analyse des anomalies dans les métadonnées pour repérer les comportements suspects. Parallèlement, diverses recherches soulignent l'efficacité des techniques de traitement du langage naturel (NLP) et l'apprentissage automatique pour détecter les fraudes, en particulier par des méthodes basées sur l'apprentissage profond (*deep learning*) permettant de reconnaître des schémas récurrents (Lopez et al., 2021; Saumya & Singh, 2022; Shahariar et al., 2019).

Par ailleurs, l'article de Si et al. (2024) explore l'utilisation de ChatGPT pour l'analyse et la détection de spam, souligne le potentiel des IAG dans ce domaine. Actuellement, l'analyse de texte fait largement appel à l'apprentissage non supervisé, avec les réseaux neuronaux artificiels et les autoencodeurs qui jouent un rôle croissant dans la détection des anomalies et des schémas frauduleux (Kumari & Sharma, 2024; Shaukat et al., 2023). Parmi les algorithmes de prédiction, le *Random Forest* se distingue pour analyser divers indicateurs de fraude. Et des méthodes multiniveaux, comme XGBoost et SVM, ont produit des résultats encore plus prometteurs pour détecter les sites de *phishing* et évaluer l'authenticité des annonces (Al-Rousan et al., 2020; Alzghoul et al., 2024; McCormick & Eberle, 2013; Nguyen & Bein, 2023; Shaukat et al., 2023).

L'avancement du *deep learning* et du NLP joue un rôle central dans la détection de la fraude. Les modèles basés sur des transformateurs, comme BERT et RoBERTa, sont utilisés pour leur capacité à saisir les contextes textuels et ainsi déterminer s'ils sont frauduleux. Par ailleurs, les réseaux de convolution (CNN), les réseaux de mémoire longue (LSTM), et les perceptrons multicouches (MLP) s'avèrent efficaces pour identifier les annonces frauduleuses en capturant des motifs complexes de fraude (Akram et al., 2024; Saumya & Singh, 2022).

Enfin, l'apprentissage par renforcement, appliqué pour adapter dynamiquement les modèles de détection aux nouvelles stratégies de fraude, améliore notablement la capacité de détection. Cette approche permet de concevoir des modèles indépendants des données propriétaires, rendant leur application plus flexible et résiliente face aux évolutions de la fraude en ligne (Ben Abdallah & Boukadi, 2023).

3.3 Profils, stratégies et recommandations

L'examen de la littérature révèle la diversité des acteurs impliqués dans les petites annonces frauduleuses, allant des individus isolés à des réseaux organisés. Leukfeldt et al. (2017) décrivent des entités organisées mettant en œuvre des stratégies transfrontalières sophistiquées. Ben Abdallah & Boukadi (2023) soulignent la grande capacité d'adaptation des cybercriminels pour échapper à la détection, tandis que Rossy & Borisova (2020) mettent en évidence l'essor du *Crime-as-a-Service*, qui renforce l'efficacité opérationnelle des cyberdélinquants. Par ailleurs, Wall (2015) et Mokhberi et al. (2024) confirment que les criminels exploitent l'anonymat et la portée mondiale d'Internet pour perpétrer des fraudes à grande échelle.

Les fraudeurs ciblent des groupes vulnérables, tels que les chômeurs, les étudiants, les personnes âgées et les nouveaux immigrants. Toutefois, selon CrowdStrike (2024) et EUROPOL (2024), les personnes âgées semblent moins affectées que les groupes plus jeunes. Pour Leukfeldt (2016) la visibilité en ligne est un facteur de risque important, affirmant que la participation active sur des forums augmente la vulnérabilité.

Afin de contrer ces menaces, plusieurs stratégies sont proposées, notamment une détection proactive, des campagnes de prévention ciblées et une sensibilisation accrue des utilisateurs (Jacquart et al., 2021; Nguyen & Bein, 2023). McCormick & Eberle (2013) recommandent le renforcement des contrôles à travers une collecte de données utilisateurs plus complète, tandis que Washha et al. (2017) proposent l'utilisation de méthodes d'apprentissage non supervisé pour réduire la dépendance aux données. Payne (2020) souligne qu'une compréhension approfondie du cybercrime est cruciale pour élaborer des stratégies adaptées, et sensibiliser les utilisateurs aux signes d'alerte et les encourager à signaler les annonces suspectes sont également des mesures essentielles (Leukfeldt & Yar, 2016).

Au niveau organisationnel, la collaboration entre plateformes, autorités légales et chercheurs est jugée nécessaire pour renforcer les capacités de détection. Lopez et al. (2021) recommandent, par exemple, une coopération étroite entre les laboratoires forensiques et les forces de l'ordre pour intégrer rapidement les données pertinentes. Sur le plan législatif, Rizka (2024) appelle à renforcer les lois de protection des consommateurs, tandis qu'Ago Thérèse Tanoh (2023) propose de consolider les réglementations et de promouvoir des solutions économiques légitimes.

En conclusion, bien que les technologies de détection progressent, les fraudeurs adaptent continuellement leurs méthodes. Les recommandations de la littérature incluent l'amélioration des systèmes de contrôle et l'utilisation du *deep learning* pour repérer les comportements suspects. Cependant, l'implication des utilisateurs par la sensibilisation et le signalement des annonces frauduleuses demeure un levier essentiel pour contrer efficacement la fraude en ligne.

4. Théorie

4.1 Entretiens exploratoires

Comment détecter : «mieux penser le numérique»

Le travail d'analyse des entretiens révèle que comprendre l'écosystème numérique est nécessaire pour renforcer l'action de sécurité. En effet, il ressort de l'analyse thématique que le problème implique différents acteurs et de nombreuses entités. Il est aussi révélé que les fraudeurs tirent parti des brèches et de tous les points faibles dont ils peuvent se saisir, afin de perpétrer leurs fraudes et obtenir un profit relatif.

« Les auteurs vont cibler des zones où le marché est tendu (...) ils utilisent souvent des moyens de contact pour sortir des processus de contrôle (...) ils utilisent les comptes des gens. Et encore pires, ils arrivent à voler des comptes à travers des escroqueries »

(Alain, Quorentin)

L'examen confirme que les fausses petites annonces de vente constituent un phénomène présentant des caractéristiques récurrentes. Les fraudes ciblent principalement certains produits en fonction des tendances actuelles ou des besoins ponctuels, tels que des billets pour le concert de Taylor Swift ou des pellets de chauffage. Cependant, les entretiens montrent que plusieurs obstacles entravent l'action de sécurité (les difficultés à prouver l'escroquerie, le manque de ressources pour agir, et un cadre légal limitant la responsabilité des annonceurs). Pour cela, une approche préventive s'avère la solution privilégiée de tous les répondants.

Comprendre : établir un cadre intégratif

La nébulosité du phénomène rend toute représentation de la problématique difficile. Cela s'illustre par un manque de définitions et de solutions, bien que tous les répondants connaissent parfaitement les populations et les modes opératoires des délinquants. À la complexité intrinsèque d'un phénomène criminel diffus s'ajoute la fragmentation des responsabilités dans la gestion de la sécurité. Tandis que certaines entités confient les enquêtes à la gendarmerie, d'autres ont formé des brigades spécialisées. En parallèle, les plateformes en ligne externalisent souvent leur sécurité à des entreprises internationales ou se basent à l'étranger, ce qui renforce les obstacles d'une approche commune et structurée. Cette nébulosité entrave une vision approfondie et cohérente du phénomène,

et il semble indéniable qu'elle soit à l'origine des difficultés rencontrées pour mettre en place des réponses coordonnées.

« On s'est déjà posé la question (...), mais on n'a pas forcément les moyens d'aller jusqu'à la compréhension (...) comprendre le phénomène est la priorité (...) on ne détecte rien » (Gilles, Jules, Alain)

En fin de compte, un certain fatalisme transparaît lorsqu'il est question de l'évolution du problème des petites annonces frauduleuses. En effet, l'augmentation des plaintes, la complexification des infractions, la rapidité d'adaptation des fraudeurs et le manque de coopération rendent toute réponse policière adéquate difficile à envisager. Malgré l'existence de technologies permettant une meilleure détection de ce type de fraude, cette distanciation semble avant tout traduire une inadéquation des institutions à faire face à une société de plus en plus informationnelle.

Annonces frauduleuses : un phénomène récurrent

Bien que les réponses des participants sur le phénomène des annonces frauduleuses dans son ensemble soient variées, l'analyse révèle une convergence concernant les fausses petites annonces de vente. Cette convergence met en évidence l'impact de ce problème et suggère la présence d'indicateurs communs à ce type de fraude. Par exemple, les délinquants ciblent souvent des objets électroniques à prix intermédiaire, permettant des gains conséquents sans attirer une attention excessive.

« C'est vrai que c'est souvent pour les mêmes articles (...) le matériel électronique (...) les produits qui ont une valeur marchande suffisante ... pour qu'ils puissent casser les prix... et se faire toujours un bon profit » (Alain, Eric)

Les entretiens révèlent plusieurs indicateurs permettant d'identifier les annonces frauduleuses. Les répondants notent que les annonces frauduleuses affichent souvent un prix en dessous du prix raisonnable ou particulièrement attractif. Toutefois, si un prix avantageux peut signaler une fraude, il n'est pas toujours fiable, surtout pour des objets rares, ce qui peut fausser l'évaluation de leur véritable valeur. La difficulté de définir un prix raisonnable pour l'investigation est ainsi soulevée. En revanche, l'indicateur lié aux profils nouvellement créés s'avère plus probant. Les fraudeurs créent régulièrement de nouveaux comptes pour éviter la détection, souvent après que leurs anciens profils aient été repérés ou annulés. Ce critère constitue un indice de fraude significatif. De plus, les répondants notent la récurrence ou la similitude des contenus dans plusieurs annonces.

Les fraudeurs réutilisent fréquemment les mêmes textes, parfois mot pour mot, dans différentes publications. Ce « recyclage malveillant » constitue un autre indicateur clé, suggérant une approche de la fraude automatisée ou systématique. L'incitation des fraudeurs à multiplier les annonces pour accroître leurs gains entraîne aussi une répétition des anomalies.

« Évidemment ... la qualité du contenu de l'annonce, la description (...) le prix trop attractif (...) l'idée c'est toujours d'avoir une annonce qui est alléchante (...) on voit que les escrocs copient d'anciennes annonces ... puis ils les remettent en ligne (...) c'est un profil relativement jeune qui est utilisé ... dans les deux dernières années maximum »
(Quorentin, Gilles, Eric)

Concernant les sites de publication d'annonces en ligne, tous les répondants citent une même plateforme comme étant actuellement le lieu propice aux petites annonces frauduleuses. Il est d'ailleurs surprenant que cette même entreprise, capable d'agir promptement et efficacement contre la pédopornographie ou le terrorisme, soit si peu fiable dans la détection des escroqueries en ligne. Pourtant, une action efficace est possible. Une plateforme locale l'a prouvé il y a quelques années, qui, suite aux avertissements des autorités, a mis en place des stratégies de filtrage et de contrôle produisant d'excellents résultats.

« Tout existe, il faut juste intégrer l'existant ! »

Un consensus émerge de l'examen des entretiens : il n'existe pas d'outils efficaces pour détecter les petites annonces frauduleuses. Bien que certaines mesures de surveillance soient en place, le traitement des fraudes repose encore largement sur la réception de plaintes. Une approche proactive, intégrant des outils de détection pour repérer les annonces frauduleuses avant qu'elles ne fassent des victimes, apparaît donc indispensable. Toutefois, le manque de compétences disponibles et la complexité des systèmes nécessaires poussent les autorités à rechercher des solutions externes.

« On n'a pas les ressources pour travailler en amont (...) nous travaillons de manière réactive (...) on essaye d'agir sur l'international, mais autant dire qu'en tant qu'acteur de police cantonale vis-à-vis d'un GAFa ... il y a une petite asymétrie ! » (Jules)

Dans ce contexte, une intensification de la collaboration internationale serait judicieuse pour contrer les activités frauduleuses perpétrées depuis l'étranger (mais personne ne semble y croire). Si certaines plateformes locales ont réussi à mettre en place des

systèmes de filtrage efficaces, les grands acteurs internationaux montrent souvent peu d'engagements à l'égard de cette problématique. Ce manque de responsabilité favorise alors la prolifération des escroqueries, et responsabiliser les plateformes paraît, bien que nécessaire, peu réaliste.

« Cette entreprise ne veut pas garantir ... une plateforme sûre (...) ils semblent n'avoir aucune intention de prendre la responsabilité, de ce qui est publié... et encore moins de ce qui est discuté après, entre le vendeur et l'acheteur » (Maël, Sébastien)

La coopération internationale se pose alors comme un défi majeur. Cette situation rend la cybercriminalité difficile à endiguer. Les répondants font face à plusieurs défis, notamment la nature transnationale des infractions et la complexité des poursuites judiciaires. En réponse, certaines instances ont choisi de ne plus engager de procédures pour les infractions mineures liées aux petites annonces. Cette décision traduit une résignation devant la complexité des procédures qui rendent difficile la mise en place d'actions efficaces contre les cyberescroqueries.

« On a les moyens d'enquête (...), mais souvent, on a de la peine (...) parce que les annonces ne sont plus disponibles lorsqu'une victime vient se plaindre (...) parce qu'ils sont à l'étranger dans des pays où la coopération judiciaire est limitée » (Sébastien, Jules)

L'analyse des entretiens met en évidence plusieurs obstacles que doit surmonter un modèle de détection. Bien que certains efforts aient donné des résultats efficaces au niveau local, des contraintes organisationnelles et réglementaires continuent de limiter les champs d'action des autorités. Une des principales pistes discutées réside dans l'amélioration des rapports avec la communauté industrielle et le renforcement des synergies entre les différentes entités de la communauté de la sécurité. Ces entretiens ont permis de mieux cerner le cadre nécessaire à la mise en place d'une détection fiable et efficace. Leur analyse souligne la nécessité de développer de nouvelles stratégies pour une approche intégratrice, capable de coordonner les efforts et d'optimiser les ressources. Par ailleurs, elle confirme l'existence d'indicateurs pertinents qui pourraient être exploités dans un modèle proactif, capable d'anticiper les fraudes avant qu'elles ne se matérialisent.

4.2 Élaboration de la théorie

Selon « le principe de l'échange » (Locard, 1920), toute activité criminelle laisse des traces et produit des signes susceptibles d'être détectés. Ce postulat conduit à l'hypothèse que le contenu d'une annonce, considéré comme une trace forensique, comporte des signes révélateurs permettant de reconnaître et d'identifier la fraude (Ribaux, 2023, p. 198). La théorie qui en découle suggère qu'il est possible de détecter les petites annonces frauduleuses en identifiant les indices de fraude présents dans les données diffusées sur Internet.

Sur cette base, un indice de fraude peut être calculé en agrégeant plusieurs signes reconnus afin de répondre à la question suivante : la probabilité indiciaire de fraude est-elle « acceptable » ou « défavorable » ? La théorie stipule notamment qu'un prix de vente inférieur au marché, des répétitions de contenu dans différentes annonces et un profil d'auteur récent augmentent significativement la probabilité qu'une annonce soit frauduleuse.

Les variables indépendantes (IV) de cette théorie sont le prix de l'offre (P), la répétition de contenu (S), et la date de création du profil de l'auteur (D). La variable dépendante (V) correspond à la probabilité indiciaire de fraude (CIBLE). L'analyse des entretiens exploratoires confirme l'existence de relations entre les variables indépendantes (IV) et la variable dépendante (V). Ces schémas de reconnaissances constituent des combinaisons spécifiques qui se cumulent dans les cas de fraude. C'est sur la base de ces relations que les hypothèses suivantes ont été formulées, en vue d'une validation empirique.

Hypothèse sur le prix bas (H1): plus une offre semble «trop belle pour être vraie» (c'est-à-dire, bien en dessous du prix du marché PM), plus la probabilité qu'elle soit frauduleuse augmente. Une annonce dont le prix est conforme au marché présente donc une faible probabilité de fraude, sauf si d'autres éléments suggèrent une intention frauduleuse.

Hypothèse sur la répétition de contenu (H2): plus une offre présente des similarités avec d'autres annonces ou, lorsque son contenu est dupliqué (c'est-à-dire, indice de similarité supérieure au taux d'unicité TU), plus la probabilité qu'elle soit frauduleuse est élevée. Ainsi, une annonce au contenu unique présente une faible probabilité de fraude, en l'absence d'autres signes ou indices frauduleux.

Hypothèse sur l'origine du profil (H3) : plus la date de création du profil de l'auteur de l'annonce est récente ou que le profil est anonyme, plus la probabilité qu'elle soit frauduleuse est élevée. Par conséquent, une annonce émanant d'un profil ancien et toujours actif est peu susceptible d'être frauduleuse, en l'absence d'autres éléments suspects.

De manière plus générale, le modèle théorique élaboré suppose que les petites annonces frauduleuses contiennent des signes distinctifs de fraude qui les différencient des annonces légitimes. Ces signes peuvent être identifiés par l'analyse d'indicateurs spécifiques. La théorie suggère qu'il est possible de détecter la fraude grâce à ces indicateurs, car les modes opératoires des fraudeurs diffèrent de ceux des utilisateurs légitimes et ils laissent des traces reconnaissables. Cette distinction permet de concevoir des mécanismes pour identifier les indices issus de ces traces numériques. Dans cette optique, deux outils ont été mis en place : l'indice de fraude et la probabilité indiciaire de fraude.

4.3 Vérification de la théorie

4.3.1 Test empirique de la théorie à l'aide de données réelles.

Le traitement et la modélisation statistique des 315 annonces collectées (Annexe 6, Annexe 7) permettent d'appliquer les mesures quantitatives suivantes à chaque annonce : le degré de similarité (SIM_SCORE), la variation du prix de vente par rapport au marché (PRICE_SCORE) et l'ancienneté du profil utilisateur (DATE_SCORE). Des paramètres de configuration empiriques (Annexe 5) ont été définis pour le calcul des mesures nécessaires au test empirique.

Taux d'unicité	Taux de similarité	Ratio prix suspect	Ratio prix normal	Seuil d'acceptation	Prix moyen
TU	TS	RPS	RPN	SA	PM
0.85	0.15	0.50	0.90	5	Annexe 5

Tableau 5 : Paramètres de configuration des tests empiriques

Analyse des signes de similitude (SIM_SCORE)

L'analyse de similarité repose sur le calcul de l'indice de similarité de Jaccard (S), et les signes sont codés dans la variable SIM_SCORE :

- Annonces identiques (SIM_SCORE = 3) : la similarité de Jaccard est égale ou supérieure au taux d'unicité ($S \geq TU$). Ces annonces suggèrent une duplication délibérée à des fins malhonnêtes.
- Annonces similaires (SIM_SCORE = 2) : la similarité de Jaccard se situe entre le taux de similarité et le taux d'unicité ($TS < S < TU$) indiquant des modifications ou des emprunts partiels.
- Annonces uniques (SIM_SCORE = 1) : la similarité de Jaccard est égale ou inférieure au seuil de similarité ($S \leq TS$), ce qui signifie que le contenu n'est pas repris.

Analyse des signes du prix en rapport au marché (PRICE_SCORE)

L'analyse des prix se base sur le ratio (R) entre le prix de vente (P) et le prix moyen du marché (PM), afin de repérer des écarts de prix significatifs susceptibles de suggérer une fraude ($R = P / PM$). Les signes sont codés dans la variable PRICE_SCORE :

- Prix suspect (PRICE_SCORE = 3) : le ratio est égal ou inférieur au ratio prix suspect ($R \leq RPS$). Le prix est anormalement bas, l'offre est suspecte.
- Prix sous-évalué (PRICE_SCORE = 2) : le ratio est compris entre le ratio prix suspect et le ratio prix normal ($RPS < R < RPN$). Le prix est inférieur à la norme, l'offre est potentiellement frauduleuse.
- Prix normal (PRICE_SCORE = 1) : Si le ratio est égal ou supérieur au ratio prix normal ($R \geq RPN$). Le prix est considéré comme conforme au marché.

Analyse des signes de création du profil (DATE_SCORE)

L'analyse de la date de création du profil (D) est nécessaire pour identifier les profils récemment créés. Les signes sont codés dans la variable DATE_SCORE :

- Date de création suspecte (DATE_SCORE = 3) : Profil créé cette année (D = 2024). Ces profils nouvellement créés sont souvent utilisés pour contourner les interdictions précédentes et diffuser de nouvelles annonces frauduleuses.
- Date de création intermédiaire (DATE_SCORE = 2) : Profil créé en 2023 ou profil anonyme (D = 2023 ou vide). Ces profils peuvent représenter à la fois des utilisateurs authentiques ou des fraudeurs expérimentés.
- Profil ancien (DATE_SCORE = 1) : Profil créé avant 2023 ($D \leq 2022$). Un profil plus ancien est considéré comme légitime.

Analyse de l'indice de fraude (INDEX)

L'indice repose sur la somme des mesures associées aux signes de fraude. Cet indice permet d'obtenir une évaluation chiffrée des signes de fraude pour chaque annonce :

$$\text{INDEX} = \text{SIM_SCORE} + \text{PRICE_SCORE} + \text{DATE_SCORE}$$

Voici les catégories indiciaires :

- Légitime (INDEX = 0) : légitimité identifiée.
- Faible (INDEX = 1, 2, 3) : les signes sont conformes et peu suspects.
- Limite (INDEX = 4, 5) : certains signes de fraude sont présents.
- Marqué (INDEX = 6, 7, 8) : plusieurs signes de fraude sont reconnus.
- Fort (INDEX = 9) : tous les indices de fraude sont présents.
- Fraude (INDEX = 10) : fraude identifiée.

Analyse de la probabilité indiciaire de fraude (CIBLE)

La probabilité indiciaire de fraude est évaluée en fonction de l'indice de fraude (INDEX) et d'un seuil d'acceptation (SA) :

- Acceptable (CIBLE = 0) : l'indice de fraude est inférieur ou égal au seuil d'acceptation ($INDEX \leq SA$). La probabilité de fraude est considérée comme acceptable pour la gestion des risques.
- Défavorable (CIBLE = 1) : l'indice de fraude est supérieur au seuil d'acceptation ($INDEX > SA$). La probabilité est jugée défavorable à une gestion des risques.

Interprétation des résultats

Le test empirique, consistant à appliquer le modèle théorique sur un premier échantillon, a permis la collecte de 315 annonces (Annexe 6). Les résultats de l'analyse descriptive de cet échantillon (Annexe 7) montrent que 2,22 % des annonces ont été identifiées comme non frauduleuses, tandis que 61,59 % ont été identifiées comme frauduleuses. Ces premiers résultats démontrent que la mise en application du modèle qualitatif a permis de détecter une majorité de cas frauduleux par rapport aux cas non frauduleux. En outre, 25,4 % des annonces collectées ont été reconnues comme frauduleuses en interprétant les signes de fraude identifiés par le modèle. Il est à noter qu'il a été impossible de classer 36,19 % des annonces en raison de divers facteurs (suppression de l'annonce par la plateforme, absence de réponse du vendeur, etc.).

Collectées	Non frauduleuses	Frauduleuses	Non classée
315	7	194	114
100 %	2.22 %	61.59 %	36.19 %

Tableau 6 : Échantillonnage du modèle théorique

Il est important de souligner que 89,21 % des annonces collectées ont été classées par le modèle théorique comme présentant une probabilité indiciaire « défavorable ». Le test expérimental s'avère concluant, car le modèle théorique a répondu aux attentes initiales. D'une part, il a permis la collecte d'un échantillon d'annonces frauduleuses, et il a reconnu et classifié les signes de fraude pour évaluer la probabilité indiciaire de chaque annonce.

Faible	Limité	Marqué	Fort	Acceptable	Défavorable
7	27	165	116	34	281
2.22 %	8,57 %	52.38 %	36.83 %	10.79 %	89.21 %

Tableau 7 : Répartition indiciaire de l'échantillon par le modèle théorique

4.3.2 Application du modèle théorique à des cas spécifiques

Le traitement des données nécessaire à la mise en application du modèle théorique a été automatisé grâce à un prototype d'aide à la détection spécialement développé pour cette recherche. Un test de performance a ensuite été effectué afin d'évaluer la qualité globale du modèle, sa capacité à identifier correctement les probabilités indiciaires, ainsi que ses éventuelles limites. Les résultats obtenus et leur interprétation sont présentés en détail dans l'Annexe 7.

Accuracy	Precision	Recall	F1-Score	Specificity	Error Rate	AUC
0.87	0.9141	0.9466	0.9301	0.2647	0.127	0.82

Tableau 8 : Test de performance du modèle théorique

Avec une précision de 91,41 % et une sensibilité de 94,66 %, les résultats montrent que le modèle reconnaît correctement la plupart des annonces « défavorables ». Cependant, la faible spécificité (26,47 %) révèle que le modèle éprouve des difficultés à reconnaître les annonces « acceptables », générant un nombre élevé de faux positifs (25). Le modèle distingue les annonces « défavorables » des « acceptables » avec une AUC de 0,82, mais des ajustements sont nécessaires pour améliorer la spécificité et réduire les faux positifs. Bien que le modèle soit efficace pour la détection de la probabilité indiciaire de fraude, il nécessite une optimisation pour mieux reconnaître les annonces « acceptables » (OpenAi, 2024; Powers, 2020).

		Nombre de cas prédits	
		Acceptable	Défavorable
Nombre de cas réels	Acceptable	9	15
	Défavorable	25	266

Tableau 9 : Matrice de confusion du modèle théorique

4.3.3 Confrontation aux hypothèses déduites du modèle théorique.

L'analyse descriptive (Annexe 7) montre les résultats suivants concernant les hypothèses :

- Hypothèse 1 (H1) :
 - Aucune annonce ayant un prix de vente proche de celui du marché (PRICE_SCORE = 1) n'a été identifiée comme frauduleuse.
 - 86,1 % des annonces « défavorables » (PRICE_SCORE = 3) ont un prix inférieur de 50 % (RPS) à celui du marché.
- Hypothèse 2 (H2) :
 - 7 % des annonces ayant un indice de Jaccard inférieur au taux de similarité TS (SIM_SCORE = 1) ont été identifiées comme frauduleuses.
 - 89,4 % des annonces « défavorables » (SIM_SCORE = 2 et 3) ont un indice de Jaccard supérieur au taux de similarité TS.
- Hypothèse 3 (H3) :
 - Aucun des profils créés avant 2023 (DATE_SCORE = 1) n'a été identifié comme frauduleux.
 - 100 % des annonces « défavorables » (DATE_SCORE = 2 et 3) ont des profils créés après 2022.

	SIM_SCORE			PRICE_SCORE			DATE_SCORE		
	1	2	3	1	2	3	1	2	3
Annonces	16.2%	73.7 %	10.2 %	2.5%	18.5 %	79 %	2.2 %	85.6 %	2.2 %
Acceptables	64.7 %	26.5%	8.8%	23.5%	55.9%	20.6%	20.6%	70.6%	8.8%
Défavorables	10.3%	79.4%	10.3%	0%	13.9%	86.1%	0%	90%	10%
Légitimes	14.2%	42.9%	42.9%	12.5%	0%	87.5%	28.6%	42.8%	28.6%
Frauduleuses	7%	77.2%	15.8%	0%	3.5%	96.5%	0%	92.1%	7.9%

Tableau 10 : Répartition des signes du modèle théorique

Les résultats du test empirique (Annexe 7) corroborent les trois hypothèses (H1, H2, H3). Concernant l'hypothèse H1, 86,1 % des annonces dont le prix de vente (P) était inférieur à la moitié de leur valeur marchande (PM) ont été classées comme « défavorables », tout comme 96,5 % des annonces identifiées comme frauduleuses.

L'analyse révèle également une tendance croissante, indiquant la possibilité d'une relation continue entre le prix de vente et la probabilité indiciaire de fraude.

De la même manière, les résultats confirment l'hypothèse H2 : seulement 7 % des annonces identifiées comme frauduleuses présentent un indice de Jaccard (S) inférieur au taux d'unicité TS ($SIM_SCORE = 1$), tandis que 95,45 % des annonces dont le contenu est réutilisé ont été classées comme « défavorables ». Les résultats corroborent l'existence d'une relation entre la redondance du contenu et la probabilité indiciaire de fraude.

On retrouve des résultats similaires pour l'hypothèse H3, avec 81,81 % des annonces identifiées créées en 2024 se révélant frauduleuses. Les résultats montrent également qu'aucune annonce provenant de profils créés avant 2023 n'a été identifiée comme frauduleuse, tandis que 90,32 % des annonces créées en 2024 sont classées « défavorables ». L'analyse confirme ainsi l'existence d'une relation entre la date de création du profil et la probabilité indiciaire de fraude.

4.3.4 Révision du modèle

La confrontation des hypothèses théoriques avec les données empiriques confirme en grande partie les hypothèses initiales. Toutefois, les résultats de l'analyse révèlent certaines limites en tant que modèle de détection. Pour y remédier, des ajustements et améliorations doivent être envisagés.

Ajustement des seuils économique : L'analyse des données confirme la validité de l'hypothèse H1 avec une corrélation entre la baisse des prix et l'augmentation des annonces identifiées comme frauduleuses. Cependant, le modèle devrait mieux intégrer les cas où une « bonne affaire » n'est pas nécessairement synonyme de fraude. Une amélioration des seuils est nécessaire, en remplaçant les paramètres fixes RPN RPS PM (Tableau 5), par des variables dynamiques, ajustées en fonction des variations environnementales ou contextuelles.

Optimisation de la détection des répétitions de contenu : Les résultats concernant les similitudes entre contenus montrent que 90,6 % des annonces dupliquées présentent une probabilité indiciaire de fraude « défavorable ». Cela suggère que cette dimension est bien capturée par le modèle, mais qu'il serait pertinent d'apporter des ajustements pour en améliorer la granularité. L'algorithme de Jaccard peut être optimisé en le combinant avec d'autres techniques d'analyse de similitude (TF-IDF, Cosinus, Jaro-Winkler, etc.)

pour une détection plus fine des réutilisations de contenu. De plus, l'ajout d'une reconnaissance d'images constituerait un élément clé pour détecter la reprise de contenu visuel.

Amélioration de l'analyse par l'ajout d'indicateur : l'ancienneté du profil, validée par l'hypothèse H2 , est un indicateur de fraude pertinent. Afin d'élargir cette analyse, il serait utile d'ajouter des indicateurs supplémentaires, comme l'activité du profil et le nombre d'interactions avec d'autres utilisateurs. D'autres signes, tels que les moyens de paiement, la fréquence de publication ou l'historique des plaintes, pourraient également accroître l'efficacité du modèle. L'intégration de ces indicateurs dans le *scoring* ou dans des algorithmes d'apprentissage automatique permettrait de réduire les faux positifs.

5. Étude de cas

5.1 Collecte de cas de fraudes et de non-cas

L'objectif de cette collecte de données (Annexe 9) est de tester la validité du modèle de détection dans un contexte élargi. Le modèle de détection est issu de la mise en application du modèle théorique, et il est confronté à un échantillonnage réel (c'est-à-dire, cette fois sans filtrage qualitatif). La collecte de l'échantillon s'est étendue sur une période de deux mois, et la préparation des données a suivi les mêmes étapes que celles décrites précédemment (4.3.1).

5.2 Approche qualitative : confrontation du modèle

Le modèle de détection a traité 2 166 cas d'annonces de vente. Parmi elles, 620 annonces ont été identifiées tandis que 1 546 annonces sont restées sans identification.

Collectées	Non frauduleuses	Frauduleuses	Non classée
2166	343	277	1546
100 %	15.84 %	12.79 %	71.38 %

Tableau : Échantillonnage de l'étude de cas

Sur les 2 166 annonces de l'étude de cas, le modèle de détection a classé 1 015 annonces comme ayant une probabilité indiciaire de fraude « acceptable » et 1 151 comme « défavorable » .

Faible	Limite	Marqué	Fort	Acceptable	Défavorable
351	664	1129	22	1015	1151
16.20 %	30.66 %	52.12 %	1.02 %	46.86 %	53.14 %

Tableau : Répartition indiciaire de l'étude de cas

Les résultats confirment les trois hypothèses (H1, H2, H3) :

- Hypothèse H1 : la corrélation entre un prix anormalement bas et une probabilité élevée de fraude est forte, avec 96,67 % des annonces à prix bas classées comme « défavorables » .
- Hypothèse H2 : les profils anonymes ou récents sont reconnus comme plus susceptibles de fraudes, avec 91 % des annonces issues de profils antérieurs à 2022 classés comme « acceptables » et 85,64 % des profils anonymes classés comme « défavorables » .
- Hypothèse H3 : la duplication des annonces est un indicateur fort, 85,37 % des annonces dupliquées étant jugées « défavorables » .

	SIM_SCORE			PRICE_SCORE			DATE_SCORE		
	1	2	3	1	2	3	1	2	3
Annonces	7.9%	84.5%	7.6%	7.3%	70.5%	22.2%	33.6%	35.5%	30.9%
Acceptables	11.2%	86.4%	2.4%	13.1%	85.3%	1.6%	65.9%	18.4%	14.7%
Défavorables	4.9%	82.9%	12.2%	2.2%	57.5%	40.3%	5.1%	50.6%	44.3%
Légitimes	0.9%	92.1%	7%	0.5%	98.6%	0.9%	20.7%	36.7%	42.6%
Frauduleuses	11.1%	11.1%	77.8%	11%	0%	89%	0%	66.7%	33.3%

Tableau 11 : Répartition des indicateurs de l'étude de cas

L'analyse de confrontation s'est concentrée sur les cas que le modèle de détection a classés avec un indice de probabilité de fraude « Fort » et « Faible » . Ces 12 cas ont été étudiés, et leur analyse révèle qu'ils correspondent tous à des annonces non frauduleuses. L'identification de leurs auteurs révèle qu'il s'agit d'annonces commerciales, publiées par des intermédiaires travaillant pour des enseignes d'électronique. Le modèle de détection a donc incorrectement classé quatre annonces légitimes en les identifiant à un indice « Fort » de fraude. L'examen de ces annonces révèle qu'elles proviennent toutes d'un même profil, créé en 2024, et qu'elles sont dupliquées. Ainsi, le modèle a confondu le mode opératoire des fraudeurs, avec une pratique commerciale agressive. Cette constatation illustre la complexité du processus

de détection des fausses petites annonces, évoluant dans un environnement où les pratiques commerciales agressives se confondent parfois avec la fraude. Cette constatation rejoint celle de Dupont (2024), qui évoque des activités criminelles prédatrices camouflées par les dérives d’une compétition exacerbée profitant d’un marché non régulé (p. 62).

5.3 Approche quantitative : performance du modèle

Cette analyse statistique est établie pour tester la pertinence de la prédiction indiciaire issue du modèle théorique. Le test de performance évalue l’efficacité du modèle de détection, et son interprétation (Annexe 7) permet d’apprécier la qualité générale du modèle ainsi que sa capacité à prédire correctement les probabilités indiciaires de fraude.

Accuracy	Precision	Recall	F1-Score	Specificity	Error Rate	AUC
0.954	0.939	0.976	0.957	0.929	0.045	0.98

Tableau 12: Test de performance du modèle de détection

L’exactitude (95,4 %) et la sensibilité (97,6 %) indiquent un bon équilibre entre la capacité à éviter les faux positifs et à détecter les fraudes. La sensibilité montre que la majorité des fraudes sont reconnues, générant peu de faux négatifs (27). La spécificité (92,9 %) confirme que le modèle est efficace pour détecter les annonces « acceptables » , malgré qu’il en confonde encore 7 % (72). Ces résultats indiquent qu’en situation réelle, et en comparaison avec le test précédent (4.3.2), le modèle parvient à limiter l’impact des faux positifs. Avec un AUC de 0,98, le modèle démontre une grande capacité de discrimination entre les annonces « défavorables » et « acceptables » (OpenAi, 2024; Powers, 2020).

		Nombre de cas prédits	
		Acceptable	Défavorable
Nombre de cas réels	Acceptable	943	27
	Défavorable	72	1124

Tableau 13: Matrice de confusion du modèle de détection

Ainsi, le modèle se révèle efficace, car il parvient à reconnaître les fraudes tout en minimisant le nombre d’erreurs dans les annonces non frauduleuses. Grâce à ces résultats, les efforts de révision à entreprendre devraient principalement viser à réduire

les faux positifs, sans nuire à la détection des fraudes. Les ajustements discutés précédemment (4.3.4) peuvent contribuer efficacement à améliorer les performances du modèle, pour atteindre un meilleur équilibre.

5.4 Discussion

En considérant les résultats présentés, il apparaît que la libre entreprise sur les plateformes de vente en ligne brouille la frontière entre pratiques légitimes et activités frauduleuses. En l'absence de réglementation dans l'espace numérique public, certains acteurs utilisent des techniques de marketing très agressives, frôlant souvent l'astuce. Il est intéressant de noter que le modèle de détection a identifié plusieurs cas qui, après analyse, se sont révélés n'être que des agents commerciaux opérant pour la promotion d'entités économiques. Bien que ces acteurs agissent dans les limites de la légalité, ils utilisent des méthodes similaires à celles des cyberescrocs (et inversement), notamment par l'usage de profils multiples et la réplique massive de contenus identiques. Cette situation met en lumière la complexité de l'écosystème cybercriminel, où pratiques commerciales agressives et activités frauduleuses peuvent se confondre. De plus, cette compétition, associée à l'absence de régulation, pousse certains acteurs du secteur commercial à adopter des méthodes de plus en plus agressives, qui influencent, elles aussi, les comportements criminels. L'étude de cas souligne les dérives de la compétitivité économique et la difficulté de distinguer les stratégies commerciales agressives des activités frauduleuses. En prenant du recul, il apparaît qu'un autre frein à l'action des autorités réside dans la perception de la faible gravité des préjudices. Dans cette perspective, et en écho aux propos de Francis : « 90 % peuvent être évités par la prévention » (Entretien 4), ce travail met en évidence qu'une solution fondée sur une approche écologique est nécessaire. Une telle solution permettrait non seulement de mieux comprendre les phénomènes et de renforcer leur prévention, mais aussi de se préparer à l'action. Et si ces objectifs sont envisageables (et cette recherche en ouvre la voie), ils nécessitent une coopération efficace au sein de la communauté de la sécurité. Pour atteindre ces objectifs, un modèle basé sur l'intelligence actionnable, fondé sur un indice de fraude, est proposé. Ainsi, comme exprimée ci-dessus, la prévention pourrait permettre d'éviter la grande majorité des fraudes enregistrées (à condition qu'elle soit intégrée dans une action proactive). Cependant, la prévention (seule), comme solution de repli face à un phénomène qui échappe au contrôle, ne saurait suffire à enrayer l'évolution de cette nouvelle délinquance.

Conclusion

Pour conclure, ce travail montre qu'il est possible de développer un modèle de détection actionnable, efficace et fiable, basé sur des indicateurs en libre accès. Il montre également que des micro-séquences de fraudes peuvent être utilisées pour calculer un indice utile à la détection des petites annonces suspectes. Ainsi, les résultats de cette recherche apportent leurs contributions en proposant les bases à un modèle de détection fondé sur l'interprétation des signes frauduleux. Et, l'approche mixte utilisée, qui combine des appréciations qualitatives et quantitatives, s'est avérée profitable à plusieurs égards. D'abord, elle aide à identifier les signes de fraude. Ensuite, elle permet d'obtenir une représentation globale du phénomène. Le modèle élaboré valide sa pertinence dans la lutte contre les petites annonces frauduleuses et pose les bases d'un déploiement à plus grande échelle. Cependant, bien que le modèle élaboré ait démontré un potentiel certain, les résultats indiquent que la théorie proposée nécessite des améliorations, car plusieurs facteurs limitants doivent être considérés. Tout d'abord, l'échantillonnage des données s'est concentré sur une plateforme spécifique, et un produit précis. De plus, bien que les indicateurs utilisés aient montré leur pertinence, la complexité des modes opératoires criminels requiert une réflexion sur l'ajout d'autres indicateurs et d'autres indices de fraude. Enfin, l'absence de collaboration directe avec les plateformes commerciales pour tester et affiner le modèle dans des conditions réelles réduit la portée des résultats obtenus. Malgré tout, les implications de cette recherche exploratoire ouvrent des pistes de développement intéressantes. Par conséquent, le modèle proposé pourrait bénéficier non seulement aux plateformes de commerce électronique pour améliorer leurs systèmes de filtrage et de prévention, mais aussi aux autorités dans le cadre de stratégies proactives. Par ailleurs, son application pourrait être étendue à d'autres domaines, tels que la détection des escroqueries financières ou l'analyse prédictive dans la veille criminelle. Pour les développements futurs, la transversalité du modèle proposé constitue un aspect clé à explorer, tout comme l'intégration du renforcement algorithmique. Mais, dans un premier temps, ce modèle pourrait être étendu à la détection d'autres formes de fraudes en ligne.

Déclaration d'authentification du travail de master

« J'atteste que le présent travail a été élaboré et rédigé par mes soins, sans l'aide de tiers et sans avoir utilisé des sources importantes autres que celles citées dans la bibliographie » .

Nombre de mots			×
	Sélection	Document	
Mots	12 337	17 026	
Caractères incluant les espaces	82 521	115 029	
Caractères excluant les espaces	70 712	98 833	
Commentaires		0	
Aide		Fermer	

Lieu et date :

Signature :

Bibliographie

- Aebi, M., Caneppele, S., & Molnar, L. (2022). *Measuring cybercrime in Europe : The role of crime statistics and victimisation surveys. Proceedings of a conference organized by the Council of Europe with the support of the European Union, 29-30 October 2020*. Eleven.
https://serval.unil.ch/notice/serval:BIB_7A3EC1088F92
- Akamai. (s. d.). Akamai. Consulté 31 octobre 2024, à l'adresse
<https://www.akamai.com/>
- Akram, N., Irfan, R., Al-Shamayleh, A. S., Kousar, A., Qaddos, A., Imran, M., & Akhunzada, A. (2024). Online Recruitment Fraud (ORF) Detection Using Deep Learning Approaches. *IEEE Access*, 1-1. IEEE Access.
<https://doi.org/10.1109/ACCESS.2024.3435670>
- Al-Rousan, S., Abuhussein, A., Alsubaei, F., Collen, L., & Shiva, S. (2020). Ads-Guard : Detecting Scammers in Online Classified Ads. *2020 IEEE Symposium Series on Computational Intelligence (SSCI)*, 1492-1498.
<https://doi.org/10.1109/SSCI47803.2020.9308544>
- Al-Sayyed, R., Alhenawi, E., Alazzam, H., Wrikat, A., & Suleiman, D. (2023). Mobile money fraud detection using data analysis and visualization techniques. *Multimedia Tools and Applications*, 83(6), 17093-17108.
<https://doi.org/10.1007/s11042-023-16068-4>
- Alzghoul, J. R., Abdallah, E. E., & Al-khawaldeh, A. S. (2024). Fraud in Online Classified Ads : Strategies, Risks, and Detection Methods: A Survey. *Journal of Applied Security Research*, 19(1), 45-69.
<https://doi.org/10.1080/19361610.2022.2124328>
- Anderson, D. R., Camm, J. D., Cochran, J. J., Sweeney, D. J., Williams, T. A., & Borsenberger, C. (2015). *Statistiques pour l'économie et la gestion* (5e éd). De Boeck supérieur.

- Avenier, M.-J., & Schmitt, C. (2007a). Élaborer des savoirs actionnables et les communiquer à des managers. *Revue française de gestion*, 174(5), 25-42.
<https://doi.org/10.3166/rfg.174.25-42>
- Avenier, M.-J., & Schmitt, C. (2007b). *La construction de savoirs pour l'action*. l'Harmattan.
- Bayley, D. H., & Shearing, C. D. (2001). *The New Structure of Policing : Description, Conceptualization and Research Agenda*. U.S. Department of Justice, Office of Justice Programs, National Institute of Justice.
- Ben Abdallah, E., & Boukadi, K. (2023). Online consumer review spam detection based reinforcement learning and neural network. *Multimedia Tools and Applications*, 83(9), 25617-25641. <https://doi.org/10.1007/s11042-023-16527-y>
- Blais, M., & Martineau, S. (2006). L'analyse inductive générale : Description d'une démarche visant à donner un sens à des données brutes. *Recherches qualitatives*, 26(2), 1-18. <https://doi.org/10.7202/1085369ar>
- Breiman, L., & Cutler, A. (s. d.). *Random forests*. Random Forests(tm). Consulté 8 octobre 2024, à l'adresse https://www.stat.berkeley.edu/~breiman/RandomForests/cc_manual.htm
- Broustau, N., Jeanne-Perrier, V., Cam, F. L., & Pereira, F. H. (2012). L'entretien de recherche avec des journalistes. Propos introductifs. *Sur le journalisme, About journalism, Sobre jornalismo*, 1(1), Article 1.
<https://doi.org/10.25200/SLJ.v1.n1.2012.16>
- Comply Advantage. (s. d.). ComplyAdvantage. Consulté 31 octobre 2024, à l'adresse <https://complyadvantage.com/>
- Confluent. (s. d.). Consulté 31 octobre 2024, à l'adresse <https://www.confluent.io/>
- Costa, L. da F. (2021). *Further Generalizations of the Jaccard Index* (No. arXiv:2110.09619). arXiv. <https://doi.org/10.48550/arXiv.2110.09619>
- CrowdStrike. (2024). *CrowdStrike Global Threat Report*.
<https://go.crowdstrike.com/global-threat-report-2024.html>

- DFAE. (2023, décembre 28). *Commerce de détail* [DFAE, Présence Suisse]. Présence Suisse.
<https://www.eda.admin.ch/aboutswitzerland/fr/home/wirtschaft/taetigkeitsgebiet/e/detailhandel.html>
- Dupont, B. (2014). La régulation du cybercrime comme alternative à la judiciarisation : Le cas des botnets. *Criminologie*, 47(2), 179-201.
<https://doi.org/10.7202/1026733ar>
- Dupont, B. (2024). *La cybercriminalité : Approche écosystémique de l'espace numérique*. Armand Colin.
- Etikan, I. (2016). Comparison of Convenience Sampling and Purposive Sampling. *American Journal of Theoretical and Applied Statistics*, 5(1), 1.
<https://doi.org/10.11648/j.ajtas.20160501.11>
- EUROPOL. (2024). *Mule financière*.
https://www.europol.europa.eu/sites/default/files/documents/be_flyers_fr.pdf
- Fingerprint. (s. d.). Fingerprint. Consulté 31 octobre 2024, à l'adresse
<https://fingerprint.com>
- Flick, U. (2022). *An Introduction to Qualitative Research*. SAGE.
- Fortin, M.-F., & Gagnon, J. (2022). *Fondements et étapes du processus de recherche : Méthodes quantitatives et qualitatives* (4e édition). Chenelière éducation.
- Francey, C., Graz, D., Fanelli, E. C., Lorenz, F., Bolzani, F., & Ghazanfari Hashemi, M. (2023). *Le Master en criminologie : Des chemins différents vers le même objectif*. École des sciences criminelles, UNIL.
- Grandjean, F., Cretu-Adatte, C., Beaudet-Labrecque, O., & Zbinden, R. (Éds.). (2022). Wenn aus einem Opfer eines Romance Scams ein Money Mule wird. *Kriminalistik*, 523-528.
- Greter, J.-P. (2020). Money mules, blanchisseuses d'argent "à l'insu de leur plein gré" ? In P. Meylan, B. Perrin, G. Fiolka, M. A. Niggli, & C. Riedo (Éds.), *Droit pénal et criminologie : Mélanges en l'honneur de Nicolas Queloz* (p. 191-203). Helbing Lichtenhahn.

- Hancock, B., Ockleford, E., Windridge, K., & others. (2001). *An introduction to qualitative research*. Trent focus group London.
- Imperva. (s. d.). Imperva. Consulté 31 octobre 2024, à l'adresse <https://www.imperva.com/>
- Jaccard, P. (1902). Distribution comparée de la flore alpine dans quelques régions des Alpes occidentales et orientales. *Bulletin de la Murithienne*, 81-92.
- Jackson, R. L., Drummond, D. K., & Camara, S. (2007). What Is Qualitative Research? *Qualitative Research Reports in Communication*, 8(1), 21-28. <https://doi.org/10.1080/17459430701617879>
- Jacquart, B., Schopfer, A., & Rossy, Q. (2021). Mules financières : Profils, recrutement et rôles de facilitateur pour les escroqueries aux fausses annonces. *Revue internationale de criminologie et de police technique et scientifique*, 74(4), 409-426.
- Johnston, L. G., & Sabin, K. (2010). Sampling Hard-to-Reach Populations with Respondent Driven Sampling. *Methodological Innovations Online*, 5(2), 38.1-48. <https://doi.org/10.4256/mio.2010.0017>
- Khichane, M. (avec Albert, P.). (2021). *Le machine learning avec Python : De la théorie à la pratique*. Editions ENI.
- Koua, A. M., Traoré, B. S., Konan, K. P., Ahounon, I., Djo, F. D. B., Aka, R. A., Kouadio, R. A., & Yeo-Tenena, Y. J.-M. (2015). Cinq vignettes cliniques sur la cybercriminalité juvénile en Côte d'Ivoire : Profil psychopathologique. *L'information psychiatrique*, 91(10), 847-852. <https://doi.org/10.1684/ipe.2015.1419>
- Kumari, A., & Sharma, I. (2024). Mitigating Malvertising Threats : An Exploration of Machine Learning Classification Algorithms for Effective Detection. *2024 International Conference on Advancements in Smart, Secure and Intelligent Computing (ASSIC)*, 1-6. <https://doi.org/10.1109/ASSIC60049.2024.10508033>
- Leukfeldt, E. R., Lavorgna, A., & Kleemans, E. R. (2017). Organised Cybercrime or Cybercrime that is Organised? An Assessment of the Conceptualisation of

- Financial Cybercrime as Organised Crime. *European Journal on Criminal Policy and Research*, 23(3), 287-300. <https://doi.org/10.1007/s10610-016-9332-z>
- Leukfeldt, E. R., & Yar, M. (2016). Applying Routine Activity Theory to Cybercrime : A Theoretical and Empirical Analysis. *Deviant Behavior*, 37(3), 263-280. <https://doi.org/10.1080/01639625.2015.1012409>
- Locard, E. (1920). *L'enquête criminelle et les méthodes scientifiques*. E. Flammarion.
- Lopez, B. E., Taylor, V. G., & McGrath, J. G. (2021, septembre). *Using Forensic Intelligence To Combat Serial and Organized Violent Crimes* [National Institute of Justice]. Nij.Ojp.Gov. <https://nij.ojp.gov/topics/articles/using-forensic-intelligence-combat-serial-and-organized-violent-crimes>
- Malik, A. A., Azeem, W., & Asad, M. (2024). Online shopping, Cyber frauds and Fraud prevention Strategies. *International Journal for Electronic Crime Investigation*, 8(1), Article 1. <https://doi.org/10.54692/ijeci.2024.0801186>
- Mancosu, M., & Vegetti, F. (2020). What You Can Scrape and What Is Right to Scrape : A Proposal for a Tool to Collect Public Facebook Data. *Social Media + Society*, 6(3), 205630512094070. <https://doi.org/10.1177/2056305120940703>
- McCormick, A. M., & Eberle, W. (2013). Discovering fraud in online classified ads. *The Twenty-Sixth International FLAIRS Conference*.
- Meo, S., & Talha, M. (2019). Turnitin : Is it a text matching or plagiarism detection tool? *Saudi Journal of Anaesthesia*, 13(5), 48. https://doi.org/10.4103/sja.SJA_772_18
- Moinet, N. (2009). Du « savoir pour agir » au « connaître est agir » : L'intelligence économique face au défi de la communication. *Les cahiers du numérique*, 5(4), 53-78. <https://doi.org/10.3166/lcn.5.4.53-78>
- Mokhberi, A., Huang, Y., Humbert, G., Obada-Obieh, B., Mehrabi Koushki, M., & Beznosov, K. (2024). Trust, Privacy, and Safety Factors Associated with Decision Making in P2P Markets Based on Social Networks : A Case Study of Facebook Marketplace in USA and Canada. *Proceedings of the 2024 CHI*

- Conference on Human Factors in Computing Systems*, 1-25.
<https://doi.org/10.1145/3613904.3641966>
- Nanath, K., & Olney, L. (2023). An investigation of crowdsourcing methods in enhancing the machine learning approach for detecting online recruitment fraud. *International Journal of Information Management Data Insights*, 3(1), 100167.
<https://doi.org/10.1016/j.jjime.2023.100167>
- Nguyen, S., & Bein, D. (2023). Data Science Analysis of Malicious Advertisements and Threat Detection Automation for Cybersecurity Progress. *2023 IEEE 13th Annual Computing and Communication Workshop and Conference (CCWC)*, 0695-0704. <https://doi.org/10.1109/CCWC57344.2023.10099325>
- OFS. (2023). *Criminalité numérique*. Office fédéral de la statistique.
<https://www.bfs.admin.ch/bfs/fr/home/statistiques/criminalite-droit-penal/police/criminalite-numerique.html>
- OFS OMN. (2023). *Omnibus 2023 : Enquête sur l'utilisation d'Internet* (Tableau No. Office fédéral de la statistique).
<https://dam-api.bfs.admin.ch/hub/api/dam/assets/29125530/master>
- Opdenakker, R. (2006). Advantages and Disadvantages of Four Interview Techniques in Qualitative Research. *Forum Qualitative Sozialforschung / Forum: Qualitative Social Research*, Vol 7, No 4 (2006): Qualitative Research in Ibero America.
<https://doi.org/10.17169/FQS-7.4.175>
- OpenAi. (2024). *ChatGPT-4o* [Logiciel].
- Payne, B. K. (2020). Defining Cybercrime. In T. J. Holt & A. M. Bossler (Éds.), *The Palgrave Handbook of International Cybercrime and Cyberdeviance* (p. 3-25). Springer International Publishing. https://doi.org/10.1007/978-3-319-78440-3_1
- Powers, D. M. W. (2020). *Evaluation : From precision, recall and F-measure to ROC, informedness, markedness and correlation* (No. arXiv:2010.16061). arXiv.
<https://doi.org/10.48550/arXiv.2010.16061>
- Ribaux, O. (2023). *De la police scientifique à la traçologie : Le renseignement par la trace*. Presses polytechniques et universitaires romandes.

- Rizka, R. (2024). Legal Protection for Consumers Who Buy and Sell Used Goods on Facebook. *International Journal of Law and Policy*, 2(4), Article 4.
<https://doi.org/10.59022/ijlp.165>
- Romelaer, P. (2005). Chapitre 4. L'entretien de recherche: In *Méthodes & Recherches* (p. 101-137). De Boeck Supérieur.
<https://doi.org/10.3917/dbu.rouss.2005.01.0101>
- Rondeau, K., & Paillé, P. (2016). L'analyse qualitative pas à pas : Gros plan sur le déroulé des opérations analytiques d'une enquête qualitative. *Recherches qualitatives*, 35(1), 4-28. <https://doi.org/10.7202/1084494ar>
- Rossy, Q. (2024, octobre 29). *Les arnaques sur Internet. Personne n'est à l'abri !* [Entretien]. <https://player.podcastics.com/playlist/5701>
- Rossy, Q., & Borisova, B. (2020). Escroqueries par Internet. In *Cybercrimes et enjeux technologiques : Contexte et perspectives* (p. 227-250).
- Saint-Cirgue, G. (2019). *Apprendre le machine learning en une semaine*.
<https://www.machinlearnia.com/apprendre-le-machine-learning-en-une-semaine>
- Saumya, S., & Singh, J. P. (2022). Spam review detection using LSTM autoencoder : An unsupervised approach. *Electronic Commerce Research*, 22(1), 113-133.
<https://doi.org/10.1007/s10660-020-09413-4>
- Sauvayre, R. (2013). *Les méthodes de l'entretien en sciences sociales*. Dunod.
<https://doi.org/10.3917/dunod.sauva.2013.01>
- Shahariar, G. M., Biswas, S., Omar, F., Shah, F. M., & Hassan, S. B. (2019). Spam Review Detection Using Deep Learning. *2019 IEEE 10th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON)*, 0027-0033. <https://doi.org/10.1109/IEMCON.2019.8936148>
- Shaukat, M. W., Amin, R., Muslam, M. M. A., Alshehri, A. H., & Xie, J. (2023). A Hybrid Approach for Alluring Ads Phishing Attack Detection Using Machine Learning. *Sensors*, 23(19), Article 19. <https://doi.org/10.3390/s23198070>

- Si, S., Wu, Y., Tang, L., Zhang, Y., & Wosik, J. (2024). Evaluating the Performance of ChatGPT for Spam Email Detection. *arXiv.Org*.
<https://doi.org/10.48550/arxiv.2402.15537>
- Srivastava, R. (2022). Identification of Online Recruitment Fraud (ORF) through Predictive Models. *Emirati Journal of Business, Economics and Social Studies, 1*, 39-51. <https://doi.org/10.54878/EJBESS.170>
- Statista. (2024). *Réseaux sociaux les plus utilisés dans le monde 2024*. Statista.
<https://fr.statista.com/statistiques/570930/reseaux-sociaux-mondiaux-classes-par-nombre-d-utilisateurs/>
- Tanoh, A. T. (2023). Usage de l'internet des jeunes ivoirien à Abidjan : Une étude comparative des communes de Koumassi et de Cocody. *Akofena, 2*(8).
<https://doi.org/10.48734/akofena.n008v02.20.2023>
- Thomas, D. R. (2006). A general inductive approach for analyzing qualitative evaluation data. *American Journal of Evaluation, 27*(2), 237-246.
<https://doi.org/10.1177/1098214005283748>
- Turnitin. (2024, juillet 10). *Understanding the Similarity Score*. Turnitin Guides.
<https://guides.turnitin.com/hc/en-us/articles/23435833938701-Understanding-the-Similarity-Score>
- Wall, D. S. (2015). *The Internet as a Conduit for Criminal Activity* (SSRN Scholarly Paper No. 740626). <https://papers.ssrn.com/abstract=740626>
- WarGames (1983)*—IMDb. (s. d.). Consulté 28 septembre 2023, à l'adresse
<https://www.imdb.com/title/tt0086567/>
- Washha, M., Mezghani, M., & Sèdes, F. (2017). *La qualité de l'information dans les réseaux sociaux en ligne : Une approche non supervisée et rapide de détection de spam. paper 15*, 247-262. <https://hal.science/hal-02871343>

Annexes

Annexe 1. Indices de la fraude

Dans le cadre de cette recherche, les hypothèses suivantes ont été utilisées pour l'identification des petites annonces frauduleuses :

Incohérences géographiques : l'auteur ne peut pas vous rencontrer, car il se trouve dans un lieu géographique éloigné.

« Comment allons nous procéder ? Je suis à Actuellement à Saint Gall pour le travail et j'ai un emploi du temps très chargé. Est-ce que tu peux venir le récupérer ?(...) soit si vous souhaitez je peux vous l'envoyer par la poste » (Alves)

Volonté de rassurer : l'auteur assure qu'il dispose d'un livreur personnel et il prend en charge la livraison.

« Je tiens à vous dire , je suis un peu pris par le travail au service et j'ai dû mettre mon iphone sous un livreur particulier qui passera vous livrer mon iphone 14 pro max avec tous ses accessoires son à jour (...) vous n'avez aucun frais à payer pour la livraison. Donc veuillez me laisser votre adresse complète suivi de votre numéro de téléphone pour une éventuelle livraison pour demain » (Nadine, Francette)

Mules financières : l'auteur dispose de plusieurs comptes TWINT ou IBAN différents, il n'est pas surpris que son compte soit bloqué et il envoie rapidement les références d'un autre compte pour le versement de l'avance.

« Oh... mais fallait me le dire depuis pour que je sache (...) sûrement que la limite est atteint oft (...) un instant je vais vous renvoyer un autre (...) vraiment toutes mes excuses... c'est la limite qui est atteinte (...) j'avais pas contrôler cela(...) faites le sur le twint de ma femme » (Elisé, Andraud).

Pression pour pousser à agir : l'auteur pousse à prendre une décision rapidement, invoquant une urgence ou un besoin immédiat.

« Je suis à la poste je n'attend que vous pour faire l'expédition (...) Veuillez répondre monsieur j'attends toujours que vous (...) Avez-vous effectué le paiement ? (...) je n'attend que vous » (Andraud, Daniel)

Mode de paiement spécifique : l'auteur demande une avance, pour le paiement il propose l'utilisation de cartes prépayées, d'IBAN étranger, de Ticket Neosurf, TWINT...

« Actuellement je suis chez ma mère à Saint-Moritz avec le téléphone (...) par quel moyen vous me payer les frais ? (...) contre remboursement de la poste (...) non j'ai envoyé un thermomix tm6 et jusqu'à présent nous n'avons pas reçu l'argent. Je suggère tout au moins un acompte et une fois le colis reçu vous m'envoyer le reste » (Daniela)

Systématisation de la fraude : l'auteur vous redirige directement vers un intermédiaire.

« Bonjour, c'est toujours disponible l'iPhone 14 pro max neuf avec ces factures a 300euros prix ferme. je vous prie de contacter directement le propriétaire uniquement pas mail pour plus de renseignements : XXX85@gmail.com (...) crée un compte WhatsApp avec votre numéro de téléphone et contact le livreur par WhatsApp » (Hasan, Jennifer)

Phishing : l'auteur demande une vérification du paiement par un moyen singulier.

« D'accord Je vais donner le top au livreur de passer vous livrer une fois que j'ai la confirmation que vos tickets sont valides (...) je vous laisse ci-dessous le site de vérification (...) alors faites la vérification et le site va vous envoyer un message dans 3 à 5 minutes pour vous confirmer la validité de vos recharges que vous allez remettre au livreur(...) Voici le site ci-dessous (...) vous ouvrez le site : <https://serviceXXXX.jimdofree.com/> Le site vous envoie un mail ou un texto sur votre numéro de téléphone et vous dira si vos recharges sont authentiques ou pas , c'est ce mail ou message que vous allez m'envoyer afin que je puisse avoir une confirmation que vos recharge sont valide » (Orlane, Birraux, Nicolas)

Les citations en italique sont des dialogues originaux tenus pendant la phase de vérification de la théorie, et les noms utilisés sont des pseudonymes utilisés par les fraudeurs.

Annexe 2. Guide d'entretien

Introduction

1. Présentation et but de l'entretien.
2. Consentement pour l'enregistrement
3. Présentation des principes de confidentialité.
4. Signature du formulaire information et consentement

Contexte et expérience

- Pouvez-vous me parler de votre parcours et de votre rôle ?
- Quelles sont vos principales observations dans le cadre de la problématique des petites annonces frauduleuses?

Les petites annonces frauduleuses

- Comment définir une annonce frauduleuse ?
- Quels indicateurs considérez-vous comme signaux d'alerte (*red flags*) ?
- Connaissez-vous et utilisez-vous des outils de détection de fraudes sur Internet ?
- Comment jugez-vous l'efficacité d'un outil de détection ?

Les fausses petites annonces de vente

1. Quels sont les principaux produits faisant l'objet de fausses petites annonces ?
2. Quelles sont les plateformes les plus ciblées ?
3. Quels sont les critères pour identifier les fausses petites annonces ?
4. Quels sont les profils des victimes et des auteurs ?

Comment détecter les fausses petites annonces, de manière efficace et fiable ?

- Centralisation / Décentralisation
- Neutralisation / Perturbation
- Prévention / Proactivité
- Automatisation / Formation

Par delà les fausses petites annonces et les petites annonces frauduleuses

1. Quels groupes ou organisations criminelles se cachent derrière cette activité ?
2. L'escroquerie est-elle l'unique objectif des auteurs de fausses petites annonces ?
3. Quels liens unissent les différentes fraudes aux petites annonces ?

Futur et innovations

- Comment voyez-vous l'évolution de cette problématique ?
- Quelles innovations technologiques ou quelles tendances jugez-vous particulièrement intéressantes à explorer ?
- Pensez-vous qu'il faut apporter des améliorations ?

Présentation du projet de recherche :

- Partage d'avis : Qu'en pensez-vous ?
- Pourriez-vous me recommander des experts ou des ressources ?
- Quels conseils spécifiques pouvez-vous donner pour le projet de recherche ?

Fin de l'entretien

- Je résume les points clés discutés
- Je vérifie si l'expert veut apporter des ajouts ou des corrections.
- Je remercie l'expert pour son temps et son expertise.

Annexe 3. Directives du fichier robots.txt de FM

Le fichier robots.txt (<https://www.facebook.com/robots.txt>) de Facebook offre un aperçu des restrictions imposées aux méthodes d'indexation pour se protéger contre l'accès et la collecte de données.

Restrictions générales

La collecte de données sur Facebook via des moyens automatisés est strictement interdite, sauf si Facebook accorde une autorisation écrite explicite. Cette règle s'applique à toutes les parties du site, sauf celles explicitement autorisées.

Agents utilisateurs spécifiques :

Amazonbot, Applebot, Googlebot, et autres bots : accès interdit .

Chemins spécifiquement bloqués :

Chemins contenant /login, /checkpoint/ sont bloqués.

Les chemins contenant /plugins/ sont bloqués.

Exceptions et accès autorisé :

L'accès à « /careers/ » est autorisé.

La fonctionnalité Safety Check, accessible via « /safetycheck/ » , est autorisée.

Implications de sécurité et légales :

Le non-respect des directives du fichier robots.txt peut entraîner une violation des conditions d'utilisation de Facebook (TOS). Cela peut potentiellement entraîner des actions en justice, notamment en cas de violation du RGPD (UE 2016/679) en Europe ou la LPD (RS.235.1) en Suisse.

Une IAG (OpenAI, 2024) a généré cette annexe.

Annexe 4. Métriques des tests de performance

Précision globale (Accuracy) : proportion de prédictions correctes parmi l'ensemble des prédictions. Mesure la capacité du modèle à classer correctement les annonces.

Précision des prédictions positives (Precision) : proportion d'annonces classées comme « défavorables » qui correspondent effectivement à ce classement.

Sensibilité (Recall) : proportion d'annonces « défavorables » que le modèle a identifiées comme telles. Cette métrique s'avère utile lorsque les faux négatifs revêtent une importance critique.

Spécificité (Specificity) : proportion d'annonces « acceptables » que le modèle a correctement identifiées comme telles.

F1-Score : Le F1-score évalue la capacité à prédire efficacement les annonces « défavorables », en faisant un compromis entre *precision* et *recall*.

Taux d'erreur (Error Rate) : mesure du degré d'erreur de prédiction du modèle par rapport au modèle réel.

Graphique du taux de vrais positifs (rappel) par rapport au taux de faux positifs pour différents seuils de décision.

Aire AUC (Area Under Curve) : mesure la capacité du modèle à distinguer les classes. Une AUC de 1 signifie une séparation parfaite des classes, tandis qu'une AUC de 0,5 indique que le modèle affiche les mêmes performances qu'un modèle aléatoire.

Matrice de confusion : tableau qui résume les résultats du modèle en quatre catégories, les Vrais Négatifs (annonces « acceptable » correctement classées comme non « défavorables »), les Faux Positifs (annonces « acceptable » incorrectement classées comme « défavorables »), les Faux Négatifs (annonces « défavorables » non détectées par le modèle, classées à tort comme « acceptable »), les Vrais Positifs (annonces « défavorables » correctement détectées comme telles par le modèle).

Cette annexe a été générée par une IAG (OpenAi, 2024; Powers, 2020).

Annexe 5. Paramètres de configuration du modèle

Taux d'unicité (TU = 0.85) :

Seuil au-dessus duquel deux annonces sont considérées comme identiques.

Taux de similarité (TS = 0.15) :

Seuil minimal pour considérer que deux annonces partagent des similarités significatives.

Seuil d'acceptation (SA = 5) :

Seuil à partir duquel l'indice de fraude est jugé plus acceptable.

Ratio prix normal (RPN = 0.9) :

Valeur de référence pour un prix considéré comme conforme au marché.

Ratio prix suspect (RPS = 0.5) :

Valeur sous laquelle le prix de l'annonce est jugé anormalement bas.

Prix du marché (PM) :

- **iPhone 13 (PM = 750)**
- **iPhone 14 (PM = 850)**
- **iPhone 15 (PM = 1200)**
- **modèle inférieur (PM = 400)**

Annexe 6. Vérification de la théorie : données collectées

Population : Annonces de vente en ligne sur FM

Échantillon : 315 annonces suspectes ont été collectées.

Individus : annonce publiée par FM.

Critères de sélection des annonces collectés (recherche) :

- Objet : iPhone 15.
- Localisation : Genève, Lausanne et Neuchâtel avec un rayon de 500 km.
- Prix : entre 200 et 600 CHF.
- Similarité des illustrations, descriptions redondantes.

Méthodologie de la collecte de données :

- Objectif : reconnaître les signes de fraude.
- Données qualitatives collectées : mode opératoire des criminels.
- Données quantitatives collectées : titre, description, prix, date de création profil.
- Source de données : Facebook Marketplace.
- Techniques de collecte : web-scraping manuel.
- Période de collecte : du 17 juillet au 31 juillet.

Préparation des données :

1. Enregistrer les données collectées sous un format unifié (CSV, SQL).
2. Suppression et traitement des doublons, incohérences.
3. Encodage des scores indicateurs (SIM_SCORE, PRICE_SCORE, DATE_SCORE, INDEX et CIBLE).

Annexe 7. Vérification de la théorie : analyse descriptive

	effectif	fréquence	PRICE_SCORE			DATE_SCORE			SIM_SCORE														
			prix normal	prix sous-évalué	prix suspect	profil ancien	aucun profil	profil récent	uniques	similaires	duplicuées												
Echantillon	315		8	2.54%	58	18.41%	249	79.05%	7	2.22%	270	85.71%	7	2.22%	31	9.84%	51	16.19%	232	73.65%	32	10.16%	
Processus de détection	7	2.22%	1	12.50%	0	0.00%	6	2.41%	2	28.57%	2	0.74%	1	14.29%	2	6.45%		1	1.95%	3	1.29%	3	7.41%
	80	25.40%	0	0.00%	6	10.34%	74	23.72%	0	0.00%	65	24.07%	3	42.86%	12	36.71%	5	9.80%	66	28.45%	9	22.22%	
	114	36.19%	0	0.00%	110	44.18%	0	0.00%	105	38.89%	105	38.89%	0	0.00%	9	29.03%	8	15.69%	88	37.93%	18	62.96%	
	114	36.19%	7	87.50%	59	82.76%	23	23.69%	5	7.143%	98	36.30%	3	42.86%	8	26.81%	37	72.56%	76	32.33%	2	7.41%	
	315	100.00%	8	100.00%	58	100.00%	249	100.00%	7	100.00%	270	100.00%	7	100.00%	31	100.00%	51	100.00%	232	100.00%	32	100.00%	
Indice de probabilité de fraude	7	2.22%	1	12.50%	0	0.00%	6	2.41%	2	28.57%	2	0.74%	1	14.29%	2	6.45%		1	1.95%	3	1.29%	3	9.38%
	7	8.57%	7	87.50%	19	32.76%	1	0.40%	5	7.143%	20	7.41%	1	14.29%	1	3.23%	21	41.18%	6	2.59%	0	0.00%	
	165	52.38%	0	0.00%	36	60.34%	130	52.21%	0	0.00%	143	52.96%	5	71.43%	17	54.84%	21	41.18%	9	58.19%	9	28.13%	
	114	36.83%	0	0.00%	4	6.90%	112	44.98%	0	0.00%	105	38.89%	0	0.00%	11	35.48%	8	15.69%	88	37.93%	20	62.50%	
	315	100.00%	8	100.00%	58	100.00%	249	100.00%	7	100.00%	270	100.00%	7	100.00%	31	100.00%	51	100.00%	232	100.00%	32	100.00%	
Probabilité indiciaire de fraude	34	10.79%	8	100.00%	19	32.76%	7	2.81%	7	100.00%													
	281	89.21%	0	0.00%	39	67.24%	242	97.19%	0	0.00%	248	91.85%	5	71.43%	28	90.32%	29	56.86%	223	96.12%	29	90.63%	
	315	100.00%	8	100.00%	58	100.00%	249	100.00%	7	100.00%	270	100.00%	7	100.00%	31	100.00%	51	100.00%	232	100.00%	32	100.00%	
Collectées	315																						
Processus de détection	7	2.22%	0	0.00%	7	100.00%	0	0.00%	0	0.00%	7	100.00%	0	0.00%	0	0.00%	0	0.00%	7	20.59%	7	0	
	80	25.40%	0	0.00%	7	0.00%	80	100.00%	114	100.00%	0	0.00%	0	0.00%	78	47.27%	2	1.72%	0	0.00%	80	28.47%	
	114	36.19%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	114	98.28%	0	0.00%	114	40.57%	
	114	36.19%	114	100.00%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	27	100.00%	87	52.73%	0	0.00%	27	79.41%	88	31.32%	
	315	100.00%	114	100.00%	7	100.00%	80	100.00%	114	100.00%	7	100.00%	27	100.00%	165	100.00%	116	100.00%	232	100.00%	282	100.36%	
Indice de probabilité de fraude	7	2.22%	0	0.00%	7	100.00%	0	0.00%	0	0.00%	7	100.00%	0	0.00%	0	0.00%	0	0.00%	7	20.59%	7	0	
	7	8.57%	27	23.68%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	27	100.00%	0	0.00%	0	0.00%	27	79.41%	0	0.00%	
	165	52.38%	87	76.32%	0	0.00%	78	97.50%	0	0.00%	0	0.00%	0	0.00%	167	101.21%	0	0.00%	0	0.00%	167	59.43%	
	114	36.83%	0	0.00%	0	0.00%	2	2.50%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	115	99.14%	0	0.00%	115	40.93%	
	315	100.00%	114	100.00%	7	100.00%	80	100.00%	114	100.00%	7	100.00%	27	100.00%	167	101.21%	115	99.14%	34	100.00%	282	100.36%	
Probabilité indiciaire de fraude	34	10.79%	27	23.68%	7	100.00%	2	2.50%	7	100.00%													
	281	89.21%	87	76.32%	0	0.00%	78	97.50%	114	100.00%	0	0.00%	0	0.00%	171	103.64%	114	98.28%	0	0.00%	34	0.00%	
	315	100.00%	114	100.00%	7	100.00%	80	100.00%	114	100.00%	7	100.00%	23	85.19%	171	103.64%	114	98.28%	34	100.00%	281	100.00%	

Annexe 8. Vérification de la théorie : analyse de performance

L'interprétation (Khichane, 2021; OpenAi, 2024; Powers, 2020) des mesures de l'analyse de performance permet d'évaluer la qualité globale du modèle et sa capacité à identifier correctement la probabilité indiciaire de fraude.

Précision (Accuracy= 0.8730) : le modèle a correctement classé 87,3 % des annonces, qu'elles soient « acceptables » ou « défavorables ». Cela inclut les vraies positives et les vraies négatives. Cependant, cette métrique ne distingue pas bien entre les faux positifs et les faux négatifs, surtout dans le contexte où il y a un déséquilibre entre les classes (peu de non-fraudes par rapport aux annonces frauduleuses).

Précision (Précision= 0.9141) : parmi toutes les annonces que le modèle a classées comme « défavorables », 91,41 % étaient effectivement « défavorables ». Cela montre que le modèle est efficace pour minimiser les faux positifs (annonces « acceptables » classées à tort comme « défavorables »).

Sensibilité (Recall or Sensitivity = 0.9466) : le modèle est capable de détecter 94,66 % des annonces « défavorables ». Cela montre que le modèle est performant pour identifier la majorité des cas « défavorables » et minimise le nombre de faux négatifs (« défavorables » ou non détectées).


F1-Score = 0.9301 : le modèle a correctement classé 87,3 % des annonces, qu'elles soient « acceptables » ou « défavorables ». Cela inclut les vraies positives (« défavorables » correctement identifiées) et les vraies négatives (annonces « acceptables » correctement identifiées).

Spécificité (Specificity= 0.2647) : seulement 26,47 % des annonces acceptables ont été correctement classées. Le modèle a donc du mal à reconnaître les annonces « acceptables », ce qui entraîne un taux relativement élevé de faux positifs (25 faux positifs dans la matrice de confusion).

Taux d'erreur (Error Rate= 0.127) : le modèle se trompe dans environ 13 % des cas. Cela inclut à la fois les faux positifs (FP) et les faux négatifs (FN), il reste des marges d'amélioration, notamment en réduisant le nombre de faux positifs et de faux négatifs.

Courbe Erreur : source de la référence non trouvée (AUC=0.82) : le modèle est globalement performant pour distinguer les annonces « acceptables » des annonces « défavorables ». Une AUC de 0,82 signifie que, dans 82 % des cas, le modèle est capable de classer correctement une annonce « défavorable » par rapport à une « acceptable ».

Matrice de confusion (VN = 9 ; FP = : 25 ; FN = 15 ; VP = 266) : Le modèle a correctement identifié 9 annonces comme « acceptables ». 25 annonces ont été erronément classées comme « défavorables » alors qu'elles ne le sont pas. Cela peut entraîner des désagréments pour les utilisateurs légitimes et suggère la nécessité d'affiner les critères de classification. 15 annonces « défavorables » n'ont pas été détectées par le modèle, ce qui représente un risque. Le modèle a correctement identifié 266 annonces « défavorables », confirmant sa capacité à détecter 84,44 % des annonces « défavorables » présentes dans le jeu de données.



Annexe 9. Étude de cas : données collectées

Population : Annonces de vente en ligne sur FM

Échantillon : 2 166 annonces ont été collectées.

Individus : annonce publiée par FM.

Critères de sélection des annonces collectés (recherche) :

- Objet : iPhone 15, 14, 13, 12.
- Localisation : Genève, Lausanne et Neuchâtel avec un rayon de 250 km.
- Prix : entre 200 et 1 700 CHF.

Méthodologie de la collecte de données :

- Objectif : reconnaître les signes de fraude.
- Données quantitatives collectées : titre, description, prix, date de création profil.
- Source de données : Facebook Marketplace (FM).
- Techniques de collecte : web-scraping manuel.
- Période de collecte : du 1er juillet au 10 octobre.

Préparation des données :

1. Enregistrer les données collectées sous un format unifié (CSV, SQL).
2. Suppression et traitement des doublons, incohérences.
3. Encodage des scores indicateurs (SIM_SCORE, PRICE_SCORE, DATE_SCORE, INDEX et CIBLE).

Annexe 10. Étude de cas : statistiques descriptives

	effectif	fréquence	PRICE_SCORE			DATE_SCORE				SIM_SCORE												
			prix normal	prix sous-évalué	prix suspect	profil ancien	aucun profil	profil créé en 2023		uniques	similaires	duplicques										
Echantillon	2166		159	7.34%	1527	70.50%	480	22.16%	727	33.56%	543	25.07%	227	10.48%	669	30.89%	171	7.89%	1831	84.53%	164	7.57%
Processus de détection																						
Identifiées non-frauduleuses	343	15.84%	2	1.26%	338	22.13%	3	0.63%	71	9.77%	29	5.34%	97	42.73%	146	21.82%	3	1.75%	316	17.26%	24	7.41%
Reconnues	259	11.96%	0	0.00%	10	0.65%	249	51.88%	0	0.00%	269	47.70%	0	0.00%	0	0.00%	0	0.58%	175	9.65%	83	22.22%
Identifiées frauduleuses	18	0.83%	2	1.26%	0	0.00%	16	3.33%	0	0.00%	0	0.00%	0	0.00%	6	0.90%	2	1.17%	2	0.11%	14	62.96%
Non Classifiées	1546	71.36%	155	97.46%	1179	77.21%	212	44.17%	656	90.23%	243	44.75%	130	57.27%	517	77.28%	165	96.49%	1338	73.07%	43	7.41%
	2166	100.00%	139	100.00%	1527	100.00%	480	100.00%	727	100.00%	543	100.00%	227	100.00%	669	100.00%	171	100.00%	1831	100.00%	164	100.00%
Indice de probabilité de fraude																						
Identifiées non-frauduleuses	351	16.20%	10	6.29%	338	22.13%	3	0.63%	79	10.87%	29	5.34%	97	42.73%	146	21.82%	11	6.43%	316	17.26%	24	14.63%
Faible	664	30.66%	123	77.36%	528	34.58%	13	2.71%	589	81.02%	48	8.84%	13	5.73%	4	0.60%	103	60.23%	561	30.64%	0	0.00%
Limite	1129	52.12%	24	15.09%	661	43.29%	444	92.60%	59	8.12%	454	83.61%	117	51.54%	509	76.08%	55	33.33%	952	51.99%	122	74.39%
Marque	22	1.02%	2	1.26%	0	0.00%	16	3.33%	0	0.00%	12	2.21%	0	0.00%	2	0.00%	2	1.17%	2	0.11%	18	10.98%
Fort	2166	100.00%	159	100.00%	1527	100.00%	476	99.17%	727	100.00%	543	100.00%	227	100.00%	659	98.51%	171	100.00%	1831	100.00%	164	100.00%
Probabilité indiciaire de fraude																						
Identifiées non-frauduleuses	1015	46.86%	133	83.65%	866	56.71%	16	3.33%	668	91.88%	77	14.18%	110	48.46%	150	22.42%	114	66.67%	877	47.90%	24	14.63%
Acceptable	1151	53.14%	26	16.35%	661	43.29%	464	96.67%	59	8.12%	465	85.64%	117	51.54%	509	76.08%	57	33.33%	954	52.10%	140	85.37%
Défavorable	2166	100.00%	159	100.00%	1527	100.00%	480	100.00%	727	100.00%	542	99.82%	227	100.00%	659	98.51%	171	100.00%	1831	100.00%	164	100.00%
Collectées																						
Identifiées non-frauduleuses	2166																					
Reconnues	343	15.84%	0	0.00%	343	100.00%	0	0.00%	0	0.00%	343	97.72%	63	9.49%	0	0.00%	0	0.00%	343	33.79%	0	0.00%
Identifiées frauduleuses	259	11.96%	0	0.00%	0	0.00%	259	100.00%	0	0.00%	0	0.00%	0	0.00%	259	22.94%	0	0.00%	0	0.00%	259	22.50%
Non Classifiées	18	0.83%	0	0.00%	0	0.00%	0	0.00%	18	100.00%	0	0.00%	0	0.00%	0	0.00%	18	81.82%	0	0.00%	18	1.66%
	1546	71.36%	1546	100.00%	0	0.00%	0	0.00%	0	0.00%	8	2.28%	654	98.49%	880	77.98%	4	18.18%	672	66.21%	874	75.93%
	2166	100.00%	1546	100.00%	343	100.00%	259	100.00%	18	100.00%	351	100.00%	717	107.96%	1139	100.89%	22	100.00%	1015	100.00%	1546	100.00%
Indice de probabilité de fraude																						
Identifiées non-frauduleuses	351	16.20%	8	0.52%	343	100.00%	0	0.00%	0	0.00%	351	100.00%	0	0.00%	0	0.00%	0	0.00%	351	34.58%	0	0.00%
Faible	664	30.66%	654	42.30%	0	0.00%	0	0.00%	0	0.00%	0	0.00%	664	100.00%	0	0.00%	0	0.00%	664	65.42%	0	0.00%
Limite	1129	52.12%	880	56.92%	0	0.00%	259	0.00%	0	0.00%	0	0.00%	0	0.00%	1129	100.00%	0	0.00%	0	0.00%	1129	98.09%
Marque	22	1.02%	4	0.26%	0	0.00%	0	0.00%	18	100.00%	0	0.00%	0	0.00%	0	0.00%	22	100.00%	0	0.00%	22	1.91%
Fort	2166	100.00%	1546	100.00%	343	100.00%	259	0.00%	18	100.00%	351	100.00%	664	100.00%	1129	100.00%	22	100.00%	1015	100.00%	1151	100.00%
Probabilité indiciaire de fraude																						
Identifiées non-frauduleuses	1015	46.86%	662	42.82%	343	100.00%	0	0.00%	0	0.00%	10	2.85%	654	98.49%	0	0.00%	0	0.00%	1015	100.00%	0	0.00%
Acceptable	1151	53.14%	884	57.18%	0	0.00%	259	100.00%	18	100.00%	0	0.00%	0	0.00%	1129	100.00%	7	31.82%	0	0.00%	1151	100.00%
Défavorable	2166	100.00%	1546	100.00%	343	100.00%	259	100.00%	18	100.00%	10	2.85%	654	98.49%	1129	100.00%	7	31.82%	1015	100.00%	1151	100.00%

Annexe 11. Étude de cas : performance prédictive

L'interprétation (Khichane, 2021; OpenAi, 2024; Powers, 2020) des mesures de l'analyse de performance permet de juger de la qualité globale du modèle, de sa capacité à identifier correctement la probabilité indiciaire de fraude.

Précision (Accuracy= 0.9543) : le modèle a correctement classé environ 95,43 % des annonces, qu'elles soient frauduleuses ou non. Cela indique que le modèle est performant dans l'identification des probabilités de fraudes, tout en préservant les annonces légitimes.

Précision (Precision= 0.9398) : le modèle identifie correctement la majorité des annonces « défavorables ». Cela signifie que, parmi les annonces détectées comme « défavorables », environ 94 % étaient effectivement « défavorables ».

Sensibilité (Recall or Sensitivity=0.9765) : le modèle détecte correctement la grande majorité des annonces « défavorables ». Cela signifie qu'environ 98 % des annonces « défavorables » présentes dans les données sont identifiées. Le modèle minimise efficacement les faux négatifs.


F1-Score= 0.9578 : le modèle est capable de bien identifier les fraudes tout en maintenant un faible nombre de faux positifs. Le F1-Score indique un excellent équilibre entre précision et sensibilité et suggère que le modèle est globalement très performant.

Spécificité (Specificity=0.92906) : le modèle est performant dans l'identification des annonces « acceptables ». Cela signifie qu'environ 89 % des annonces légitimes sont correctement identifiées comme « acceptables », réduisant ainsi le risque de faux positifs.

Taux d'erreur (Error Rate=0.0457) : le modèle se trompe dans environ 4.5 % des cas. Ce taux d'erreur est bas, le modèle est globalement précis dans ses classifications.

Courbe ROC (AUC=0.98) : le modèle a une capacité très élevée à distinguer les annonces « défavorables » des annonces « acceptables », ce qui en fait un modèle particulièrement efficace pour la détection de la fraude.

Matrice de confusion (VN = 943 ; FP = : 72 ; FN = 27 ; VP = 1124) : Le modèle a correctement identifié 943 annonces comme « acceptables », 72 annonces « acceptables » ont été incorrectement classées comme « défavorables ». Ce nombre montre que le modèle génère peu de faux positifs. 27 annonces « défavorables » n'ont pas été détectées. Le modèle a correctement identifié 1 124 annonces « défavorables », ce qui montre sa capacité à capturer les indices de fraudes efficacement.



Annexe 12. Fichiers externes

1. Demande de ratification du travail de recherche
2. Formulaire d'information et de consentement
3. Transcription entretien 1
4. Transcription entretien 2
5. Transcription entretien 3
6. Transcription entretien 4
7. Transcription entretien 5
8. Transcription entretien 6
9. Fichier CSV des données collectées pour la vérification de la théorie
10. Fichier CSV des données collectées pour l'étude de cas
11. Fichier Excel pour l'analyse descriptive
12. Code Python pour l'analyse inférentielle
13. Visuel de l'interface d'aide à la détection